

百度大规模微服务架构下的

故障全面预防 精细止损 深度观测

甄真



2021 InfoQ 技术大会近期会议推荐

一一盘点一线大厂创新技术实践

❷北京站

全球大前端技术大会

时间: 2021年07月04-05日

地点: 北京 · 国际会议中心



❷ 深圳站



时间: 2021年07月23-24日

地点: 深圳・大中华喜来登酒店



个人介绍

履历

2013: 加入百度搜索团队

2013-2016: 负责搜索核心模块的业务架构

2016-今:负责搜索全系统架构优化

现在

搜索稳定性团队技术负责人

稳定性工程

云原生架构

基础技术

服务 系统 空用 组件





背景

。微服务架构

- ・服务多
- 拓扑复杂
- 依赖多
- ・迭代频繁

故障产生概率大

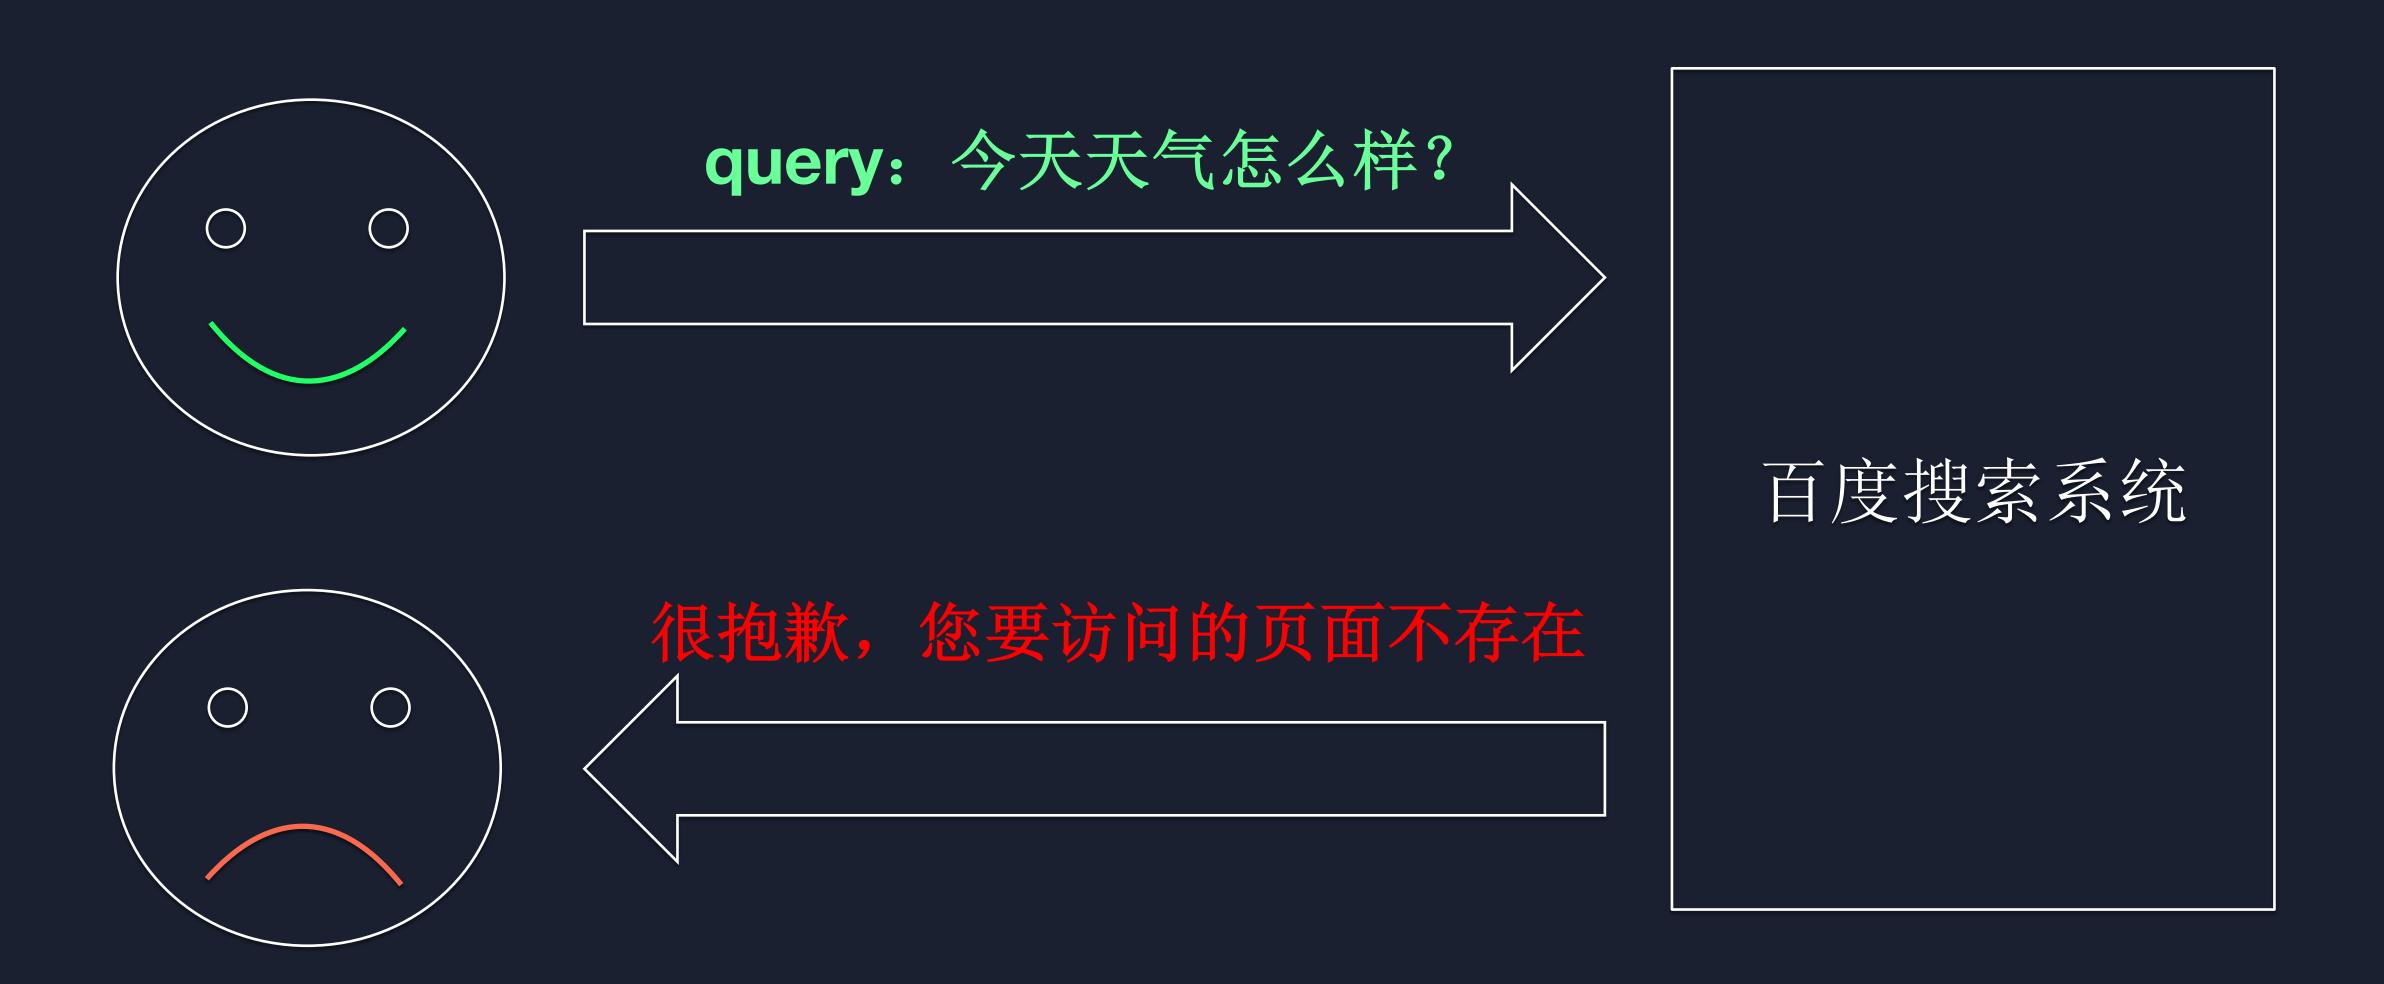




背景

故障典型症状——拒绝

目标:尽最大努力服务好每一个query,减少拒绝







"数"说百度搜索系统的复杂性

可用性要求

NO万台机器

N大地域

NOO种服务

NO PB数据

极端

N0万变更/天

NOO种故障

NOO人参与

NO亿PV/天

参照表		
系统可用性	不可用时间/年	
90%(1个9)	36.5天	
99%(2个9)	3.65天	
99.9%(3个9)	8.76小时	
99.99%(4个9)	52.56分	
99.999%(5个9)	5.26 分	
99.9999%(6个9)	31.54秒	





百度搜索系统介绍



搜索在线系统



倒排、正排、摘要



抓取、建库系统





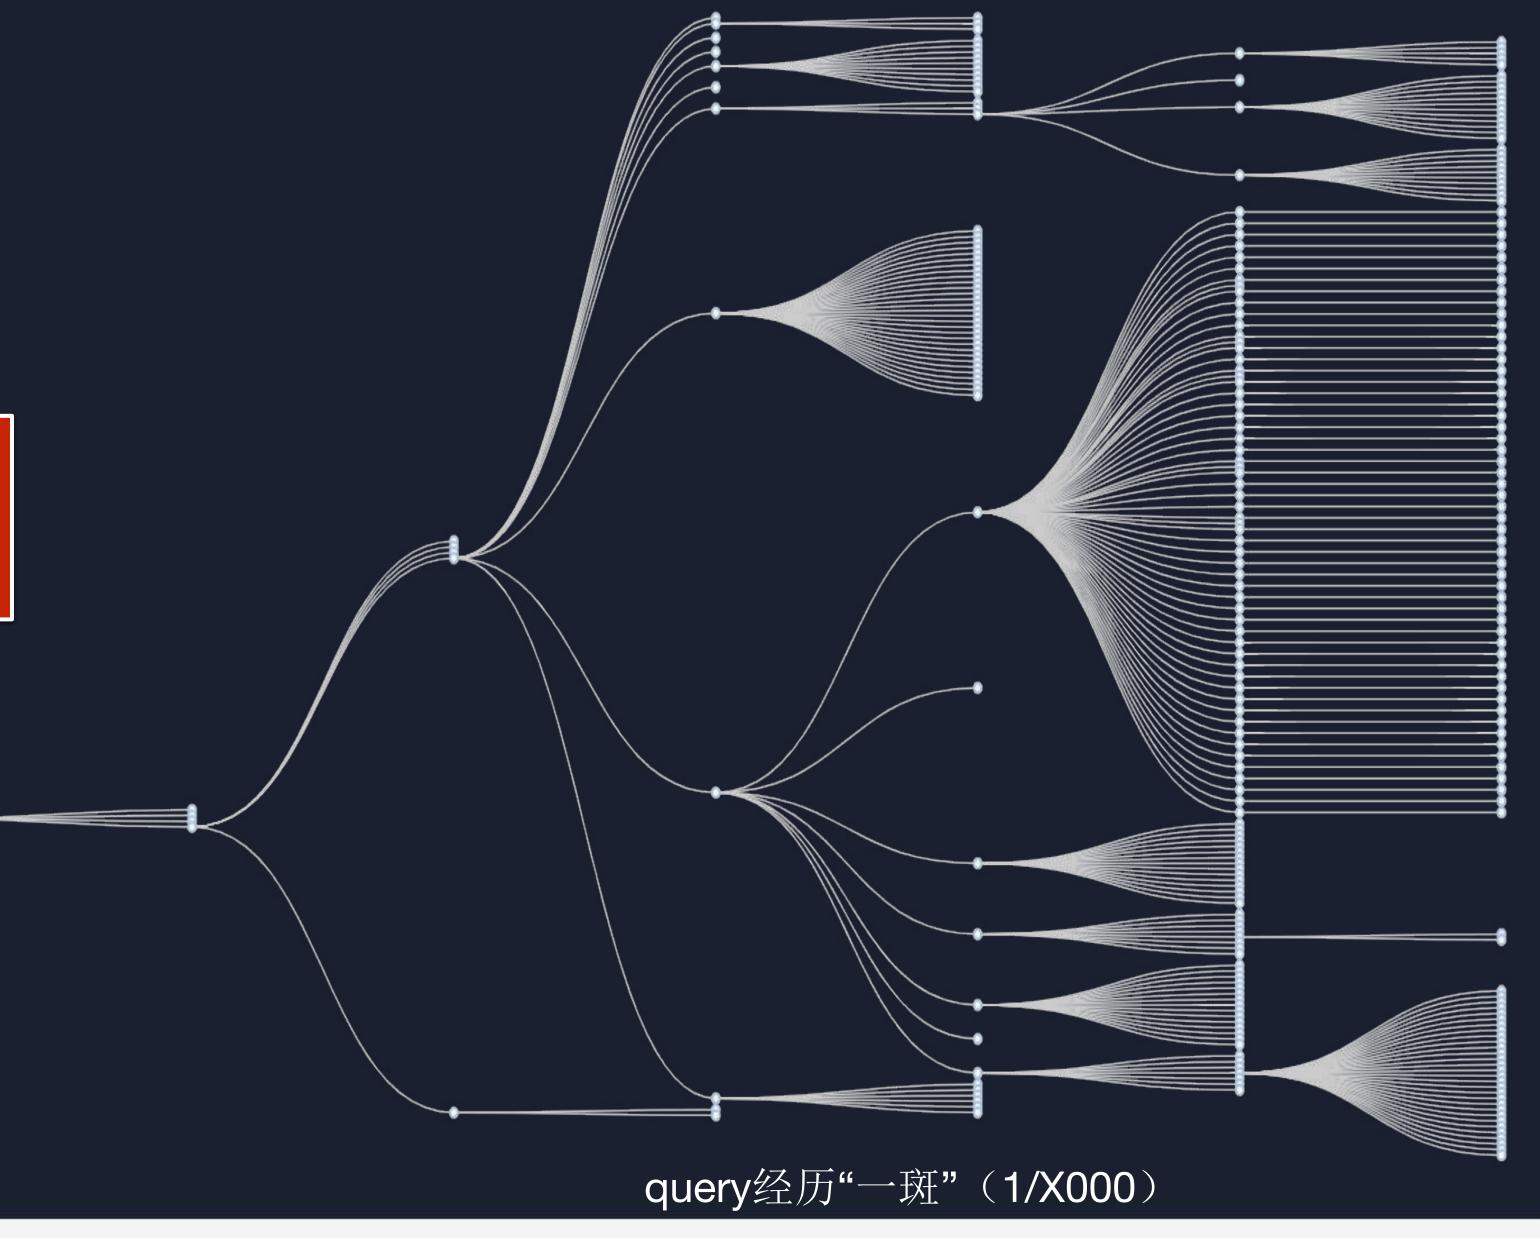


一个query在搜索系统的处理过程



拒绝是一件多么容易发生的事!

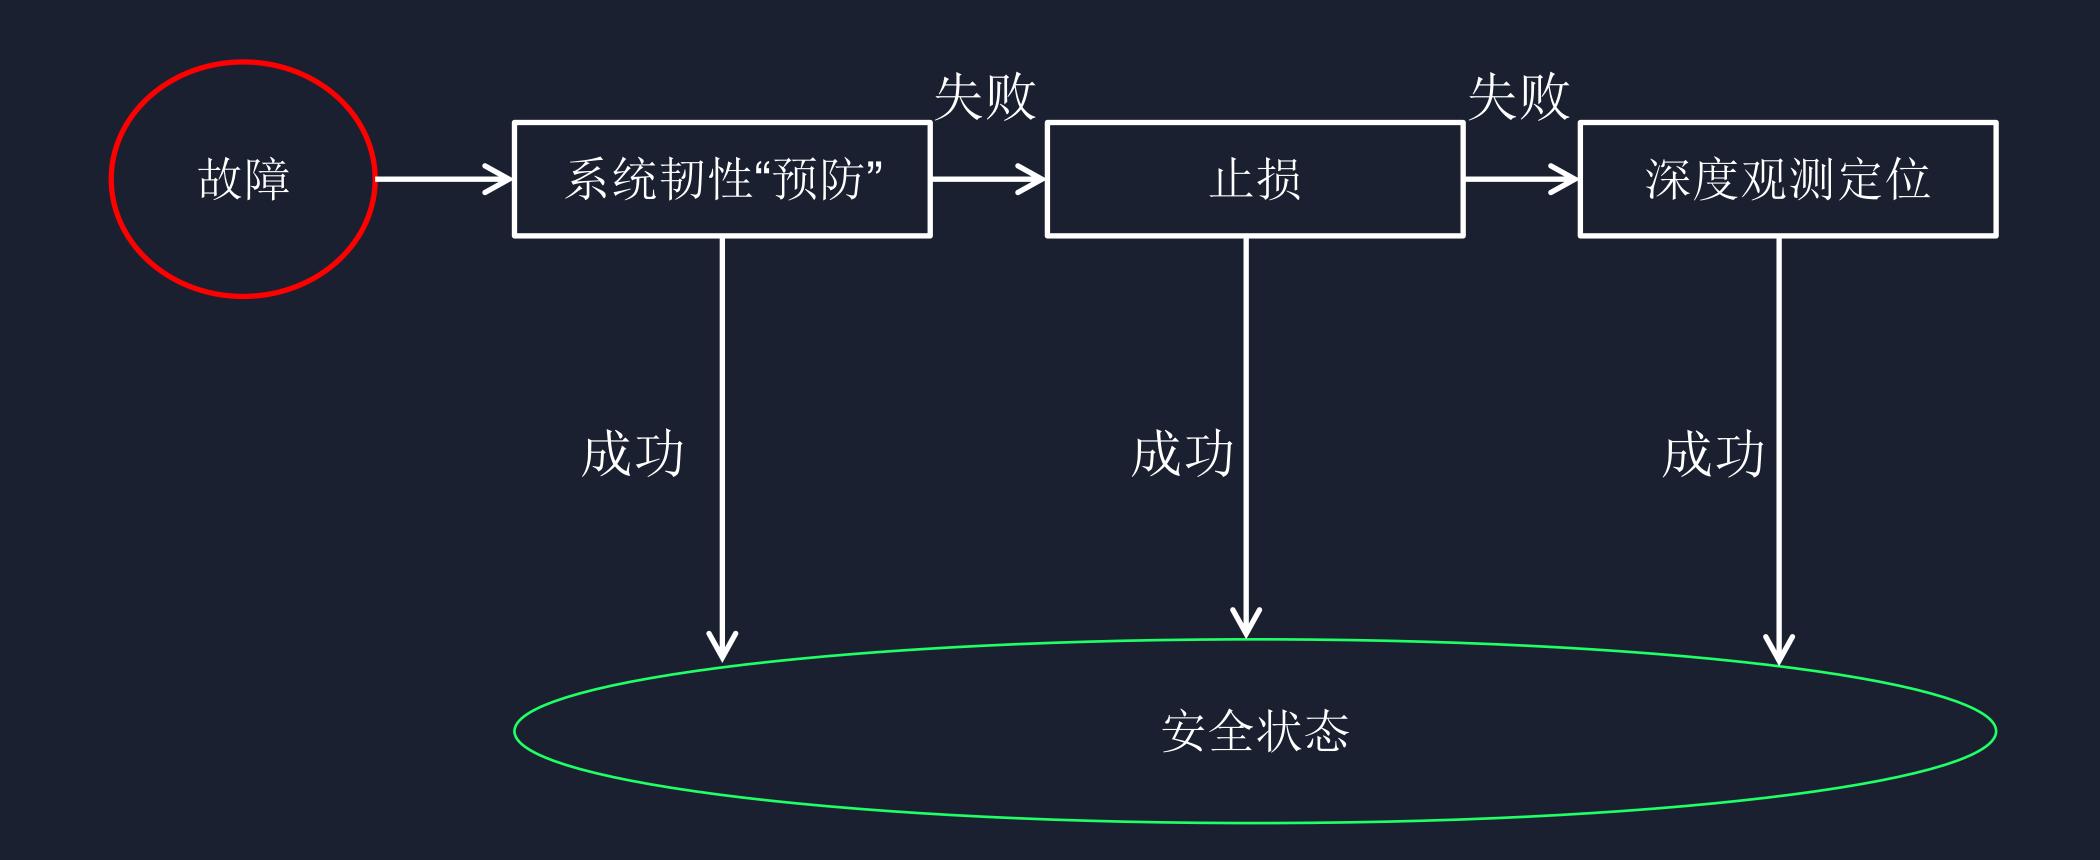
 $\begin{array}{c}
10000 \\
0.99999 \\
10000 \\
0.999999 \\
= 0.99
\end{array}$







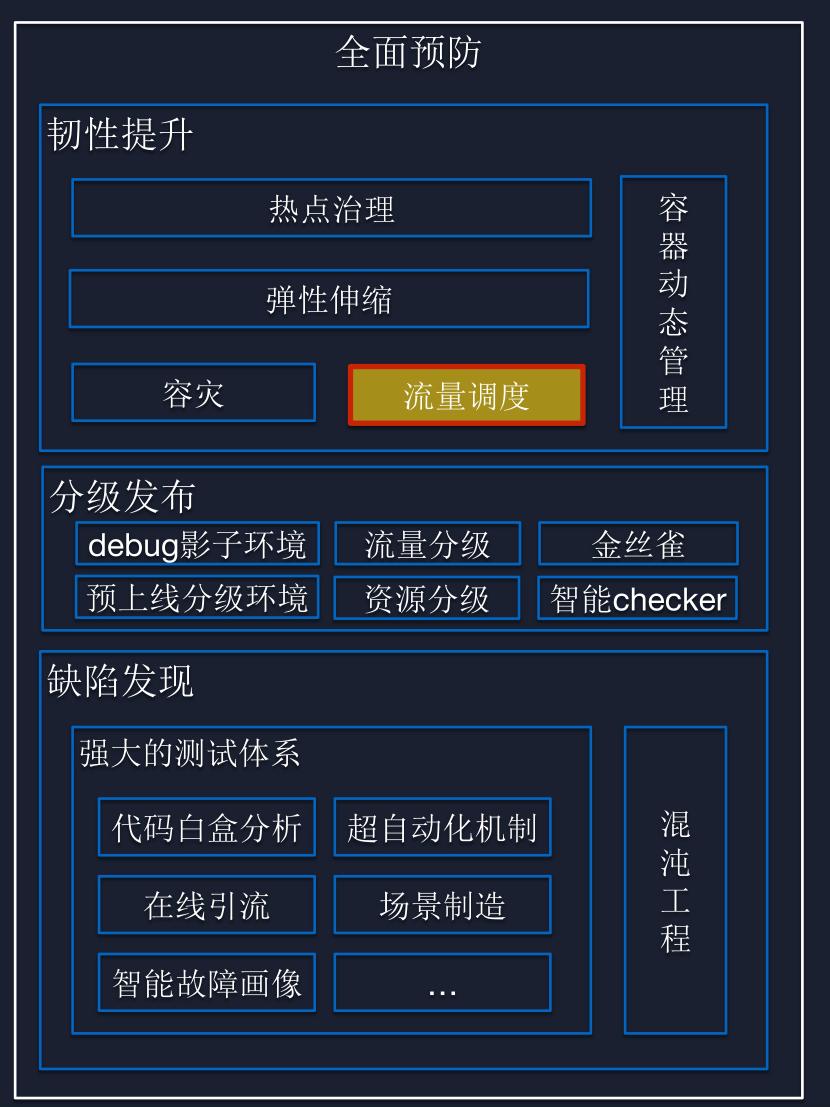
永远不要指望故障不发生,必须把故障当作常态

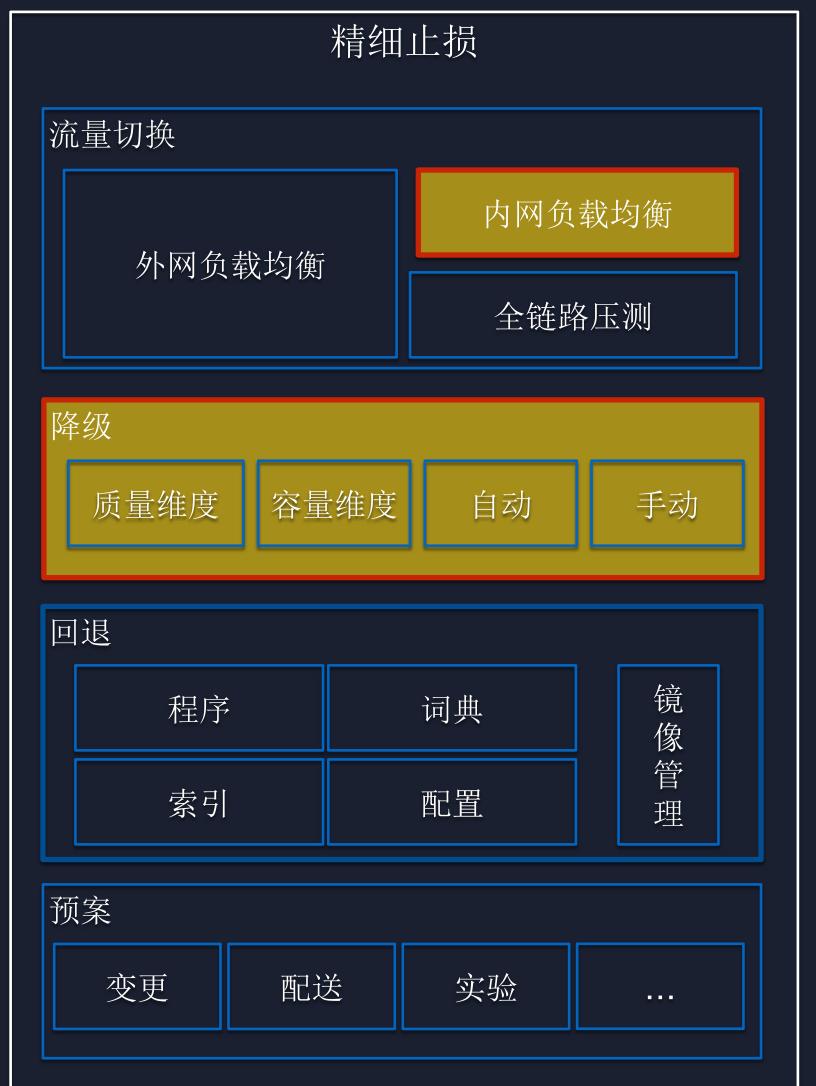


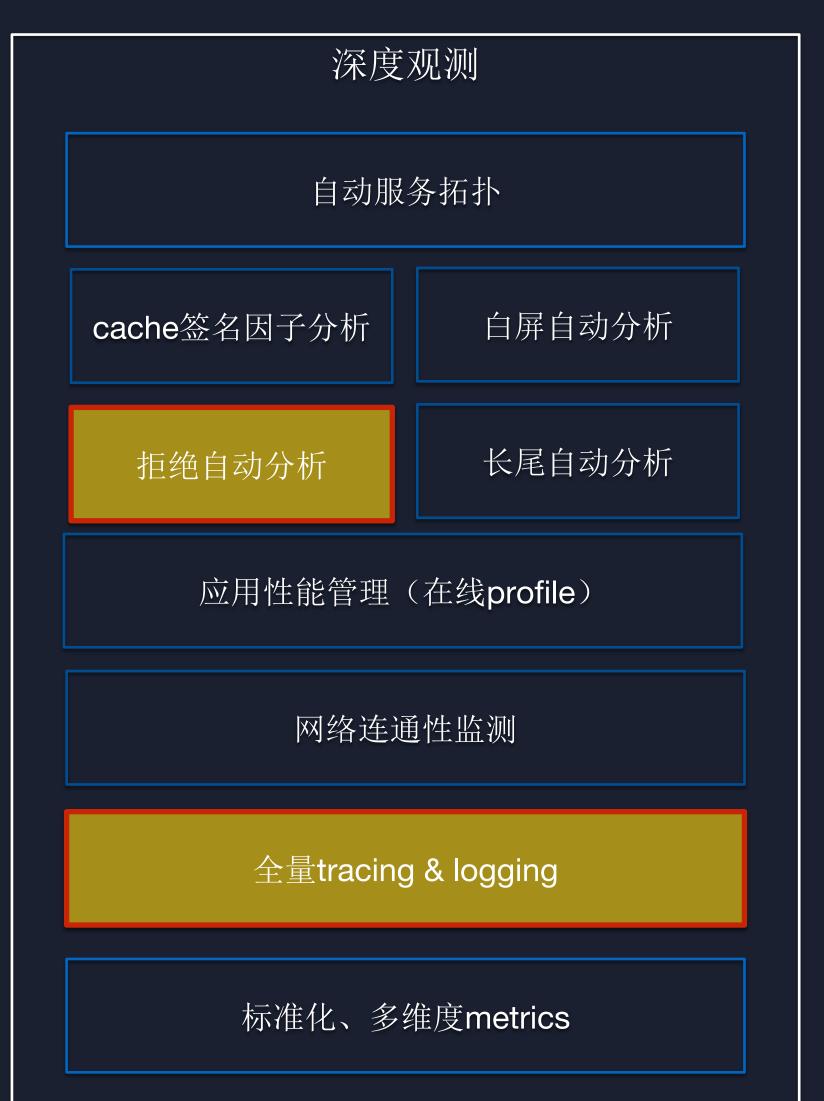




百度高可用技术栈



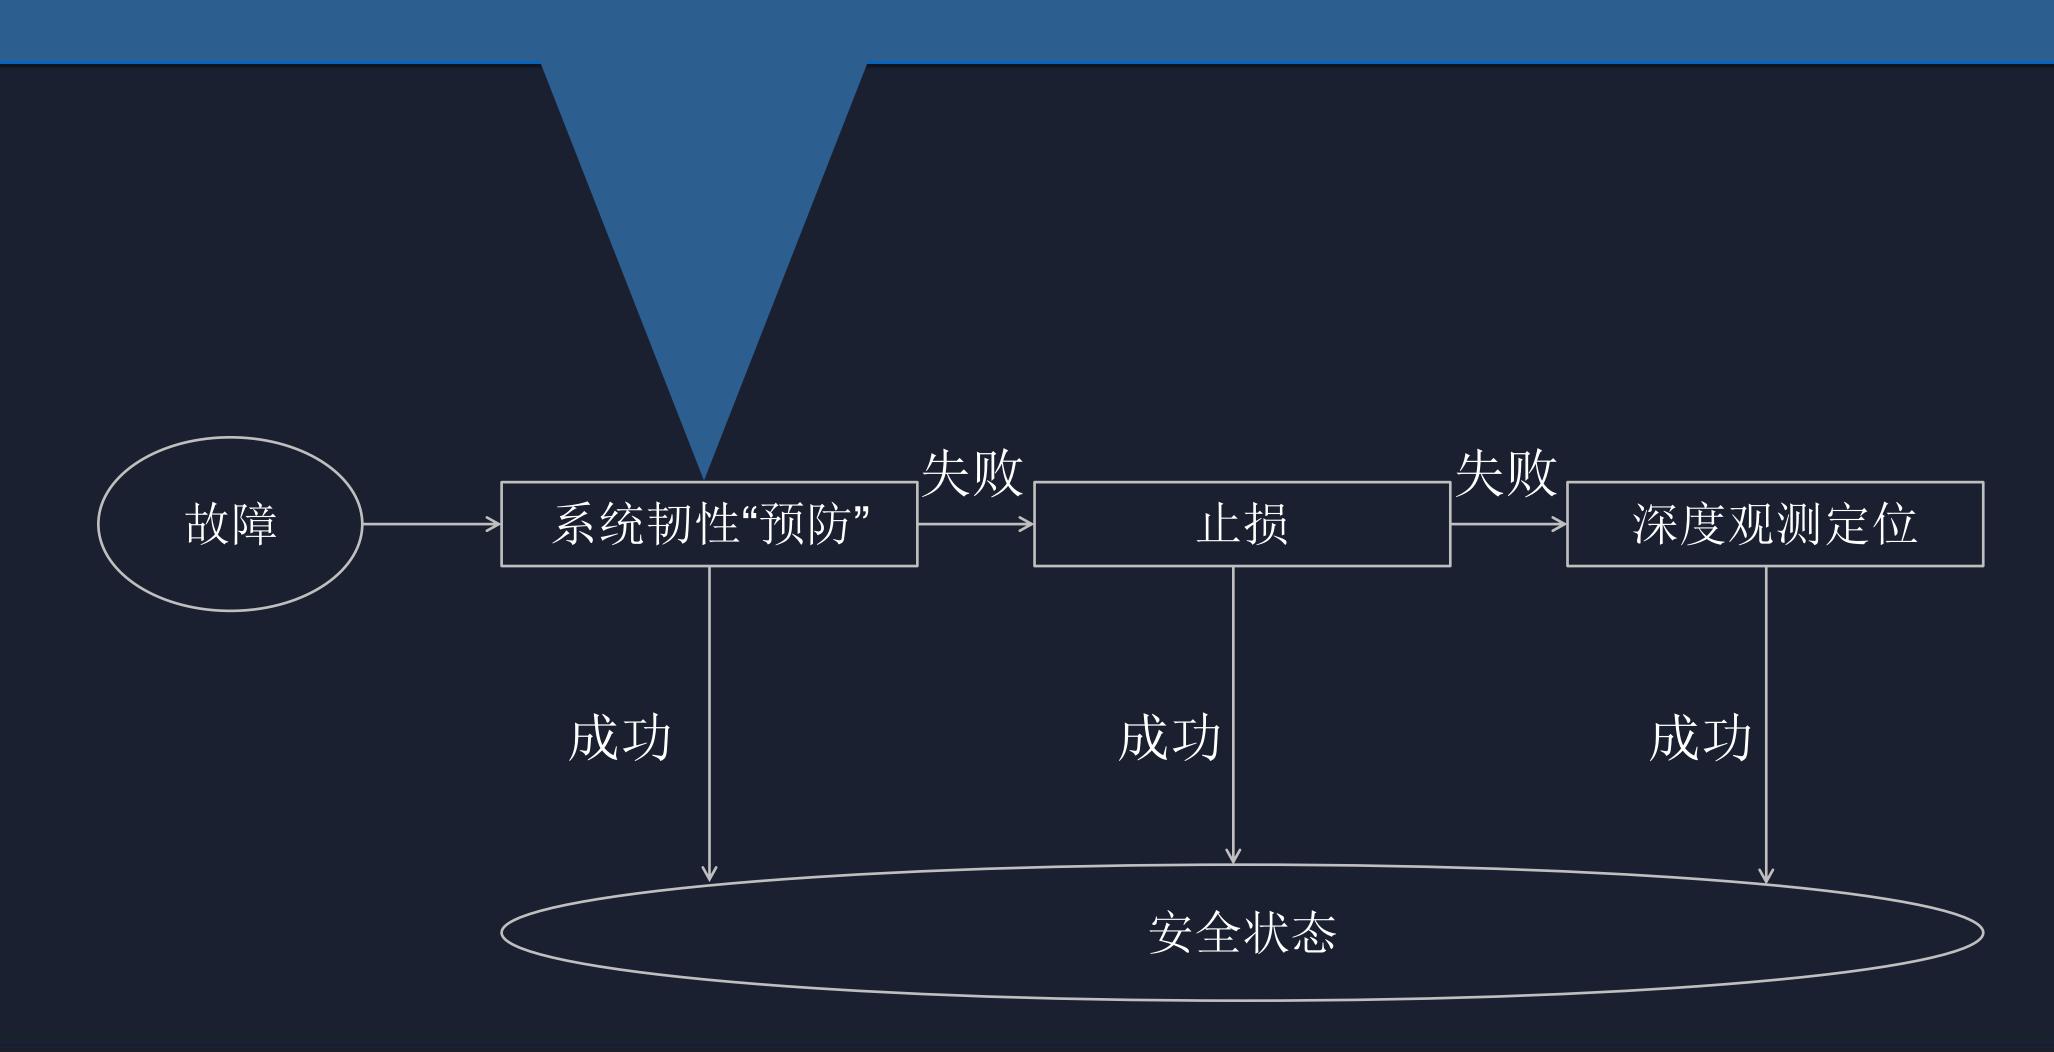








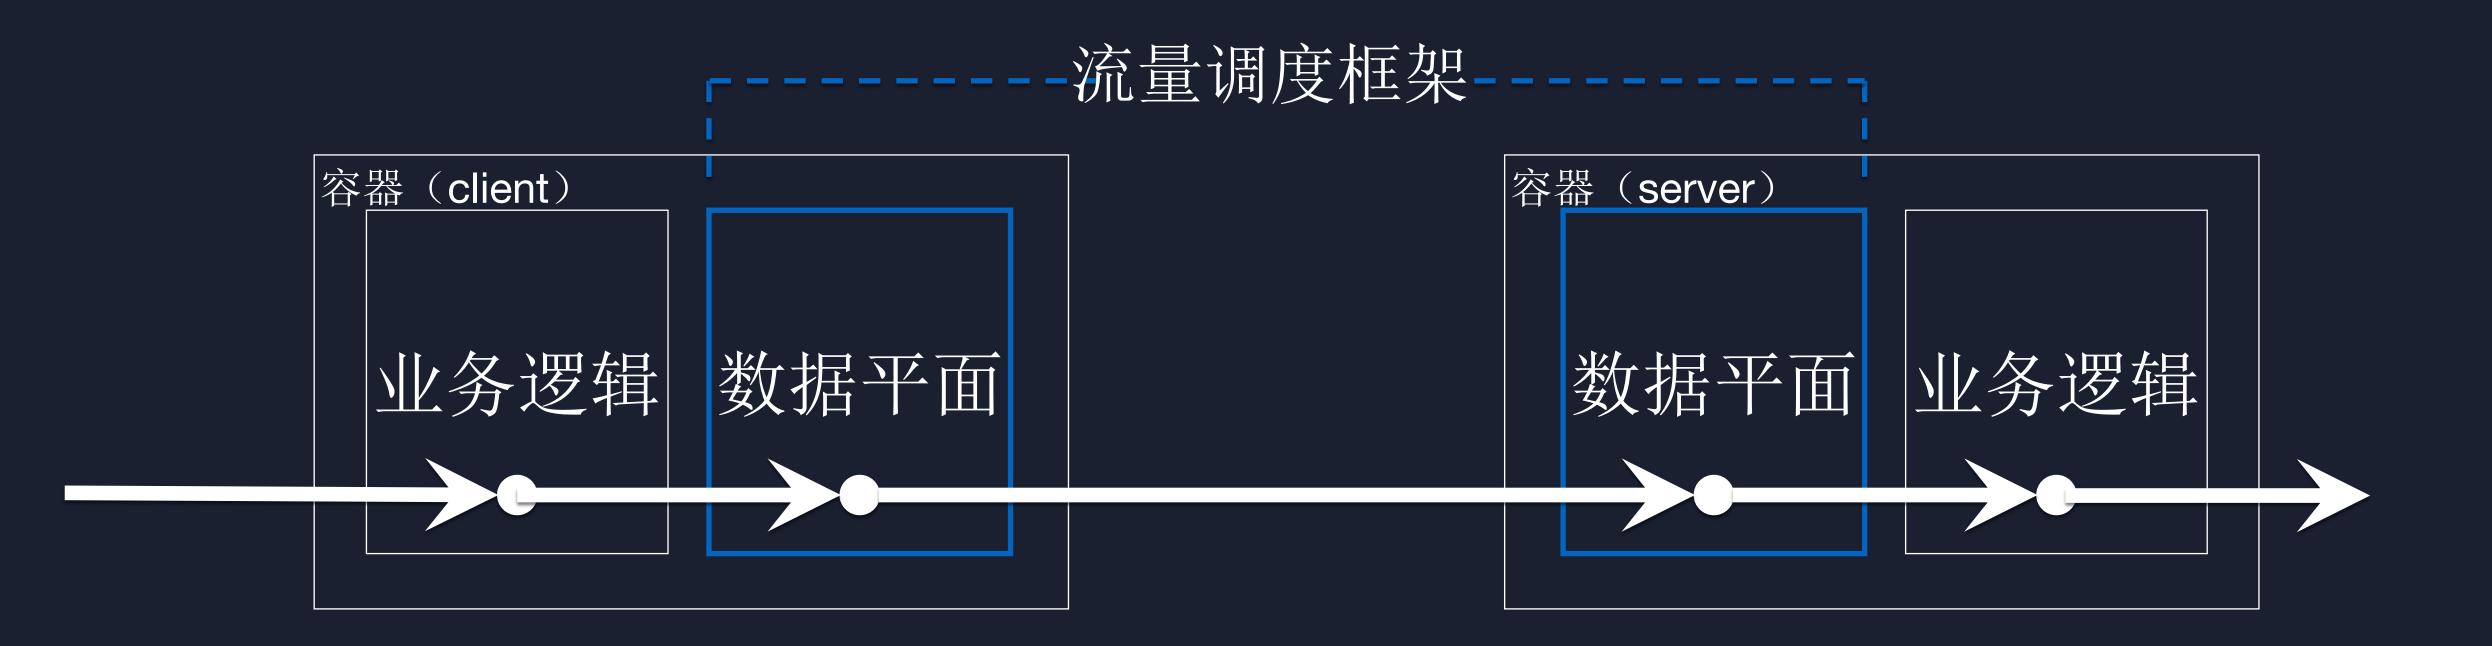
全面预防一一流量调度







全面预防: 流量调度框架

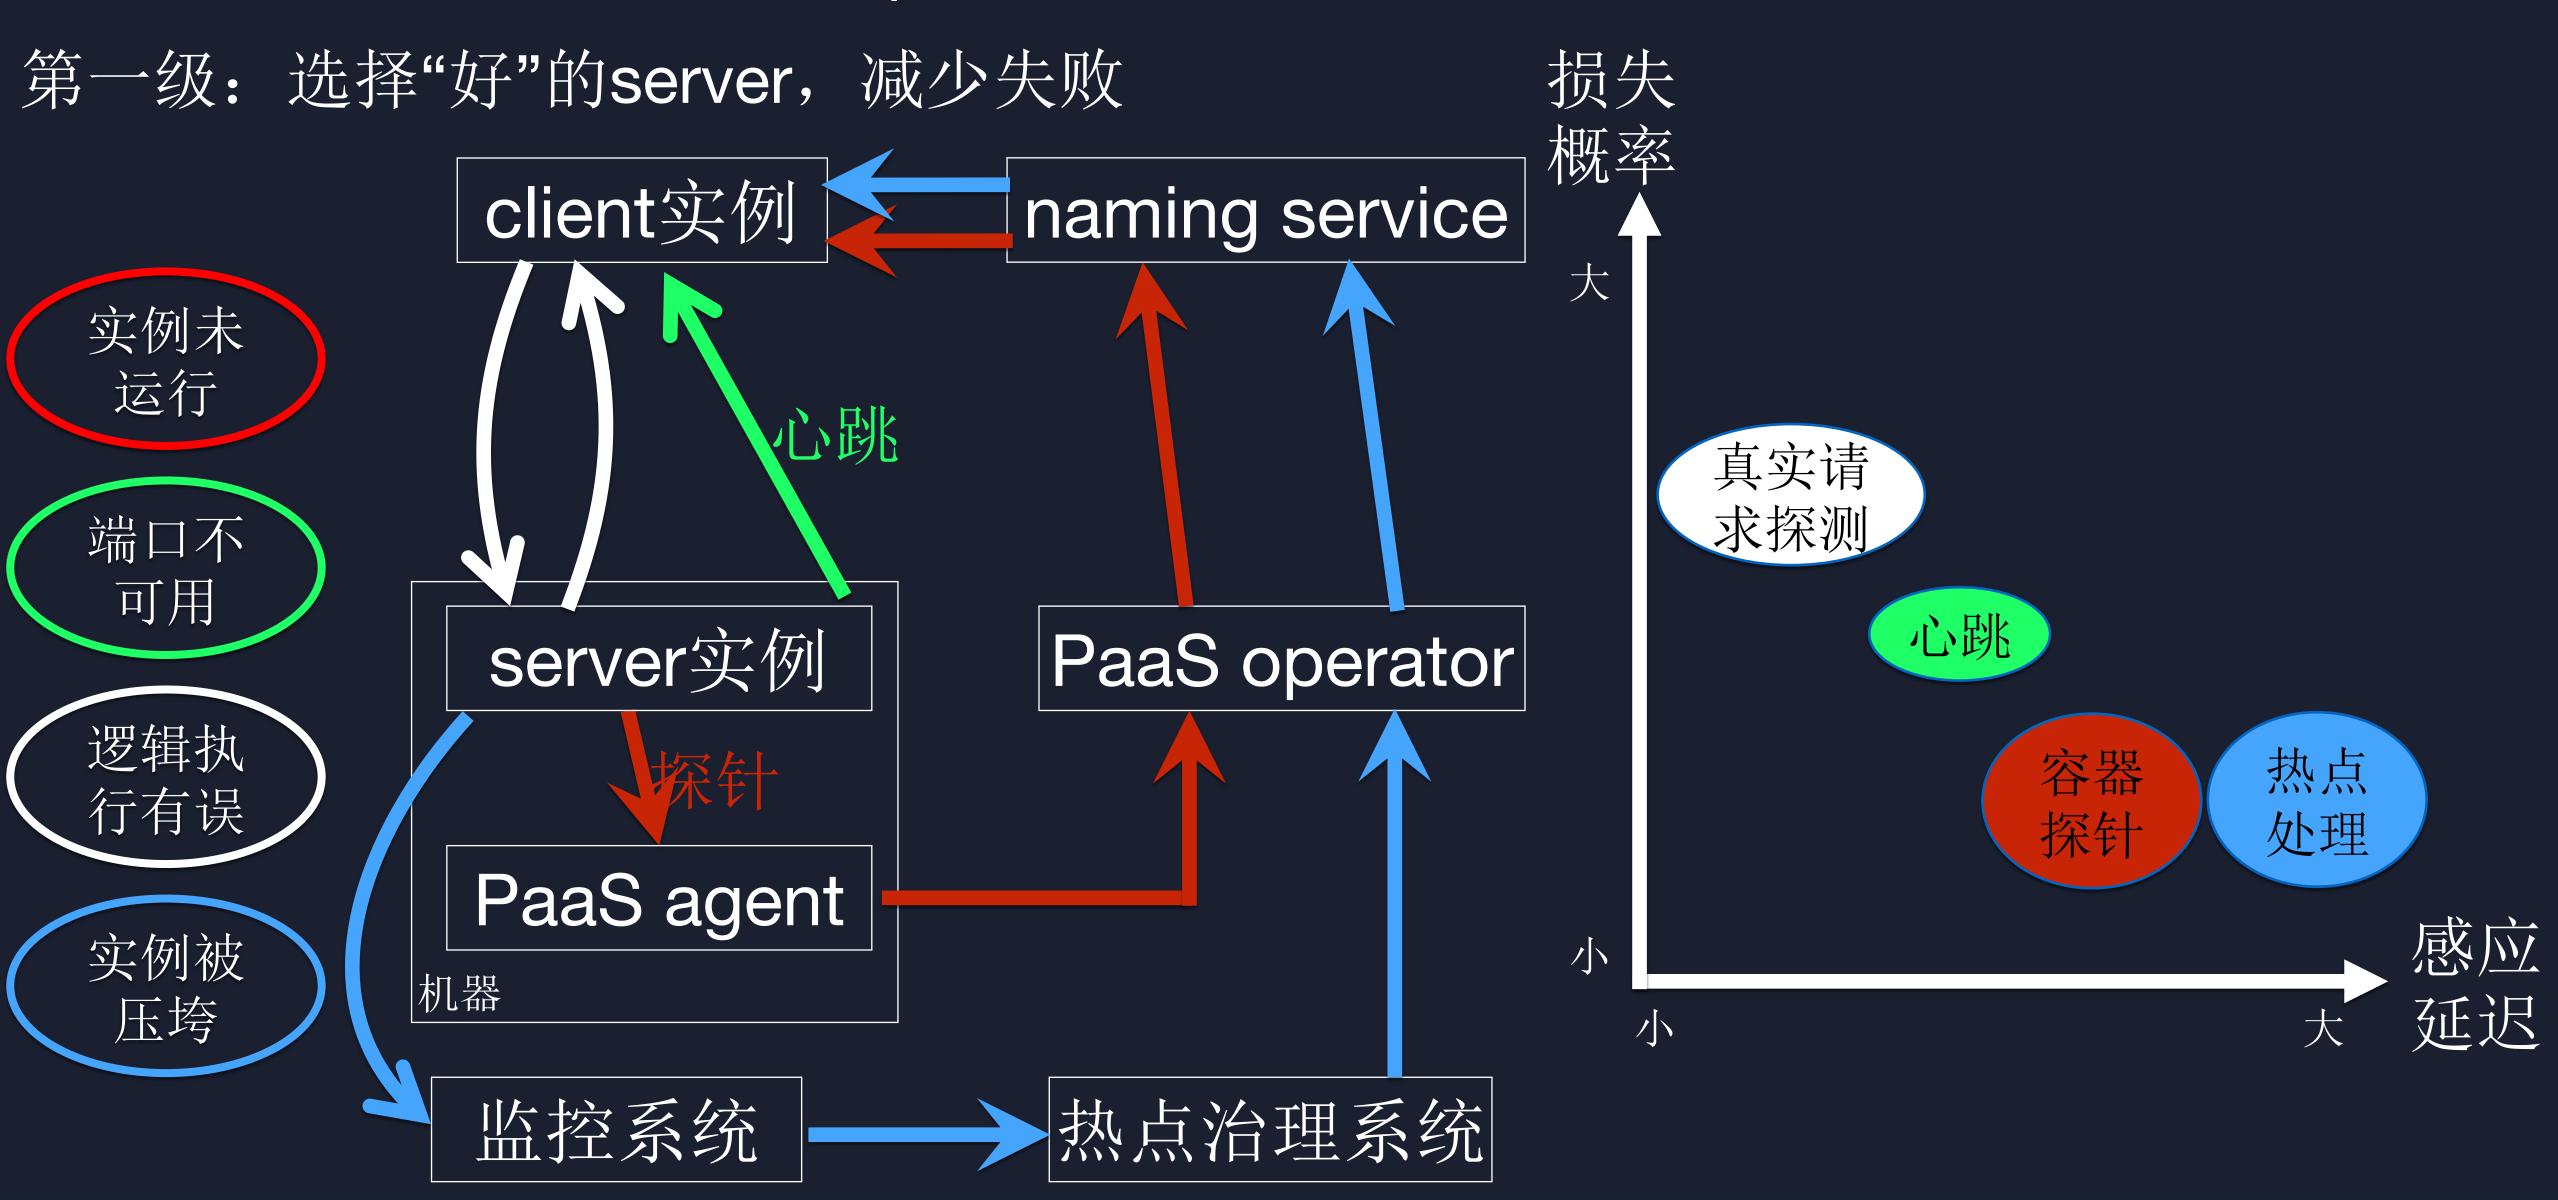








全面预防: 流量调度框架 可用性感知

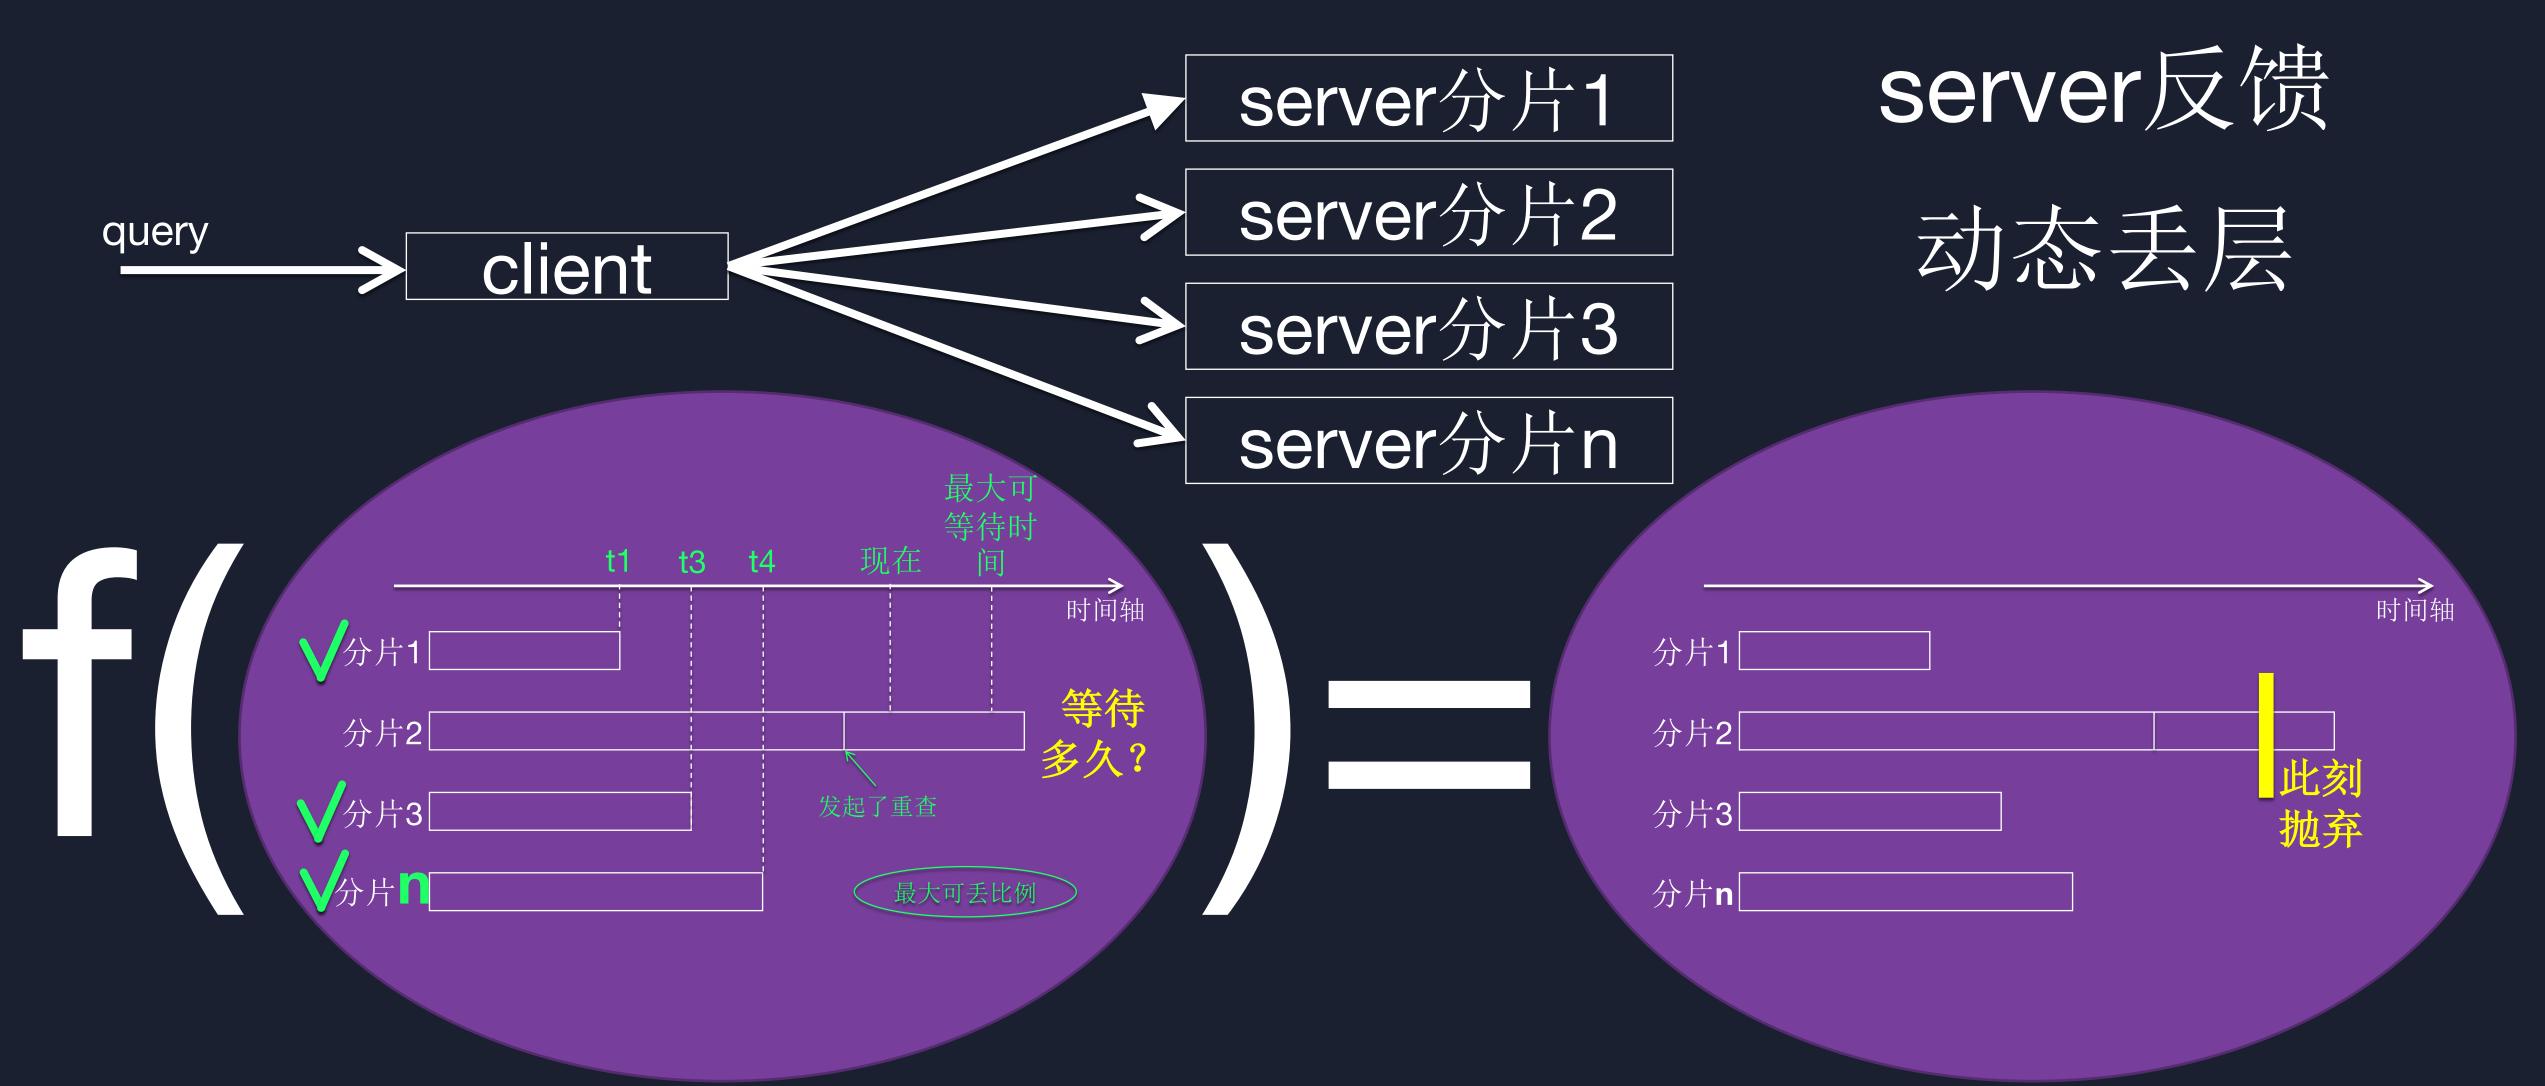






全面预防: 流量调度框架 流量控制——分片场景

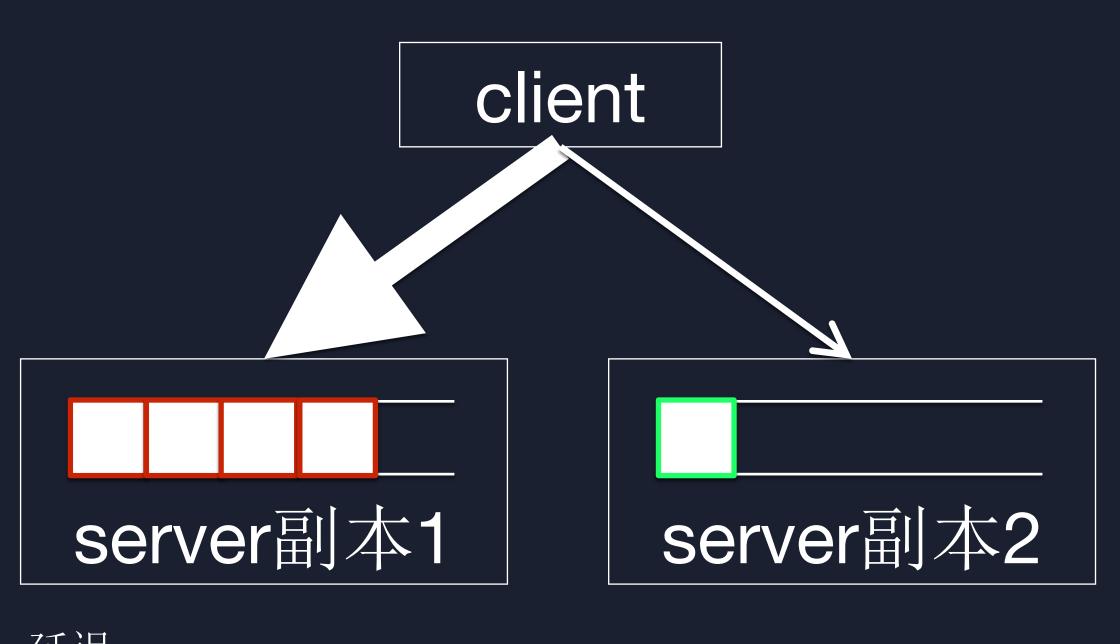
第二级:分片服务下,勇于"壮士断腕",减少超时风险





全面预防: 流量调度框架 负载均衡——副本场景

第三级:多副本时,均衡化延迟,减少超时风险



延迟	
	client server replica1
	server replica2
	一一一一一一一一

算法	特性	使用场景
random	随机打散	server实例处理能力相同
round robin	依次调度	server实例处理能力相同
query word hash	按query内容哈希选取	请求具有聚集性,且server 具备本地cache
静态weight	按权调度	server实例处理能力存在稳 定的不同
动态weight(latency aware)	根据server延迟按权调度	server承载流量大,处理能 力随时间变化
动态weight(cache aware)	使server副本本地cache数 据产生差异,减少整体盘IO	server副本存在本地cache, query按更小的组成粒度访 问这些cache
•••	•••	•••

最佳实践

1. Random、RR 用全集群容量应对极 端热词 结合外围机制杀热点 2. 动态weight 用于召回层: 大吞吐, 少副本

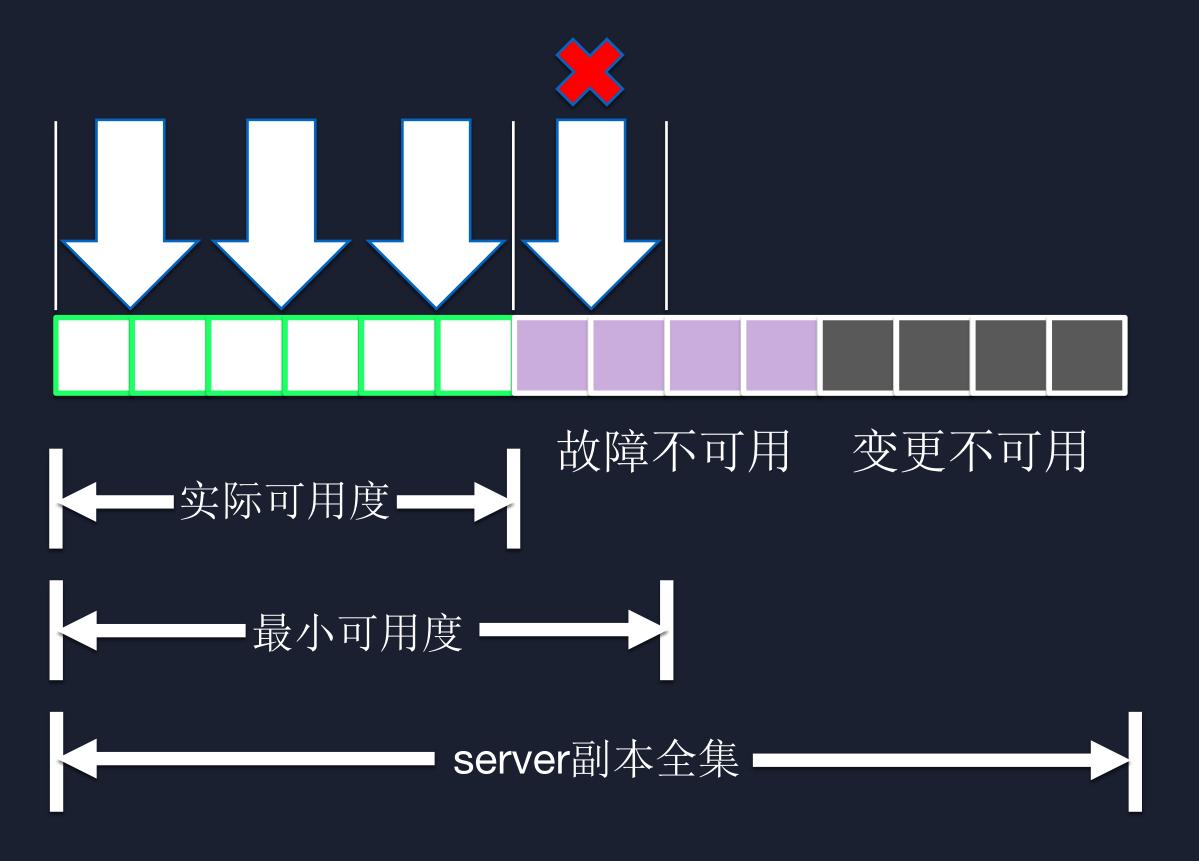


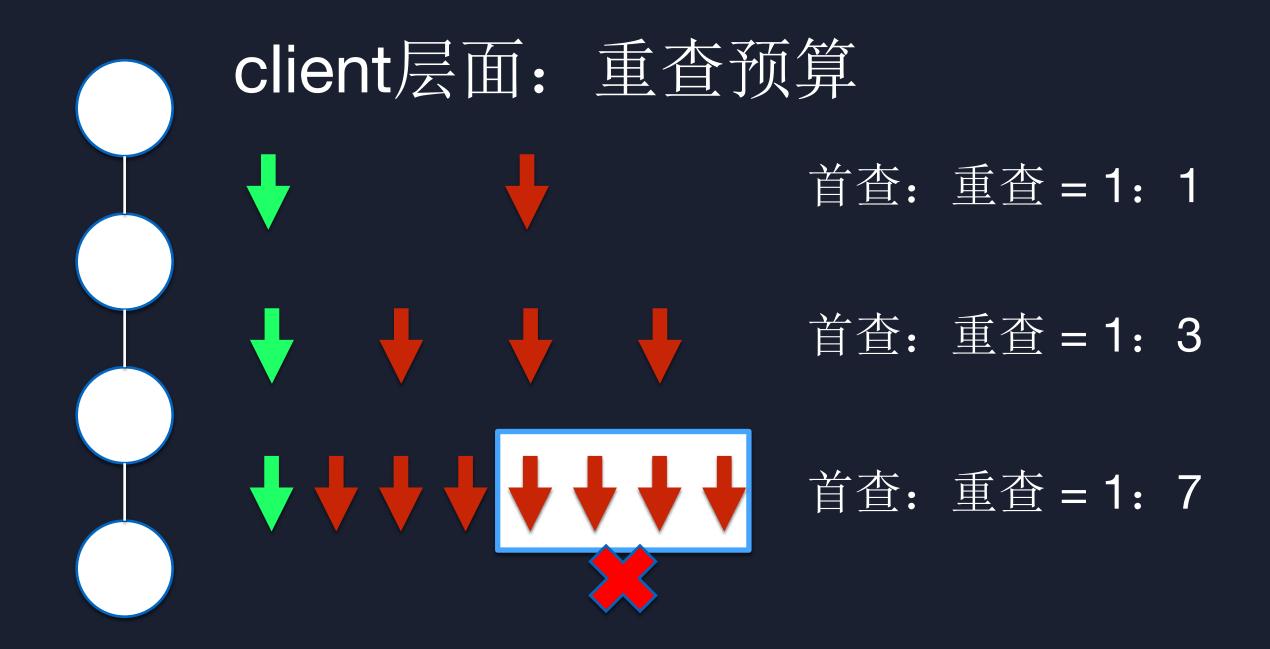


全面预防: 流量调度框架 服务级别的保护

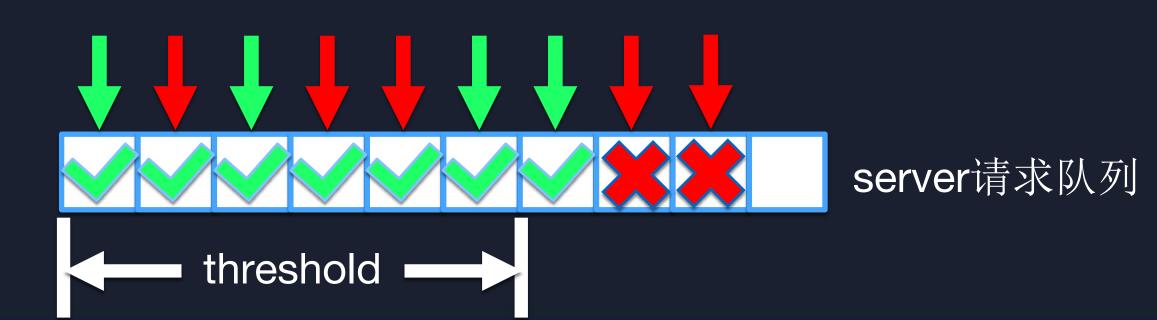
第四级: 牺牲少数, 保护多数, 减少损失

client层面: 通过可用度保护server



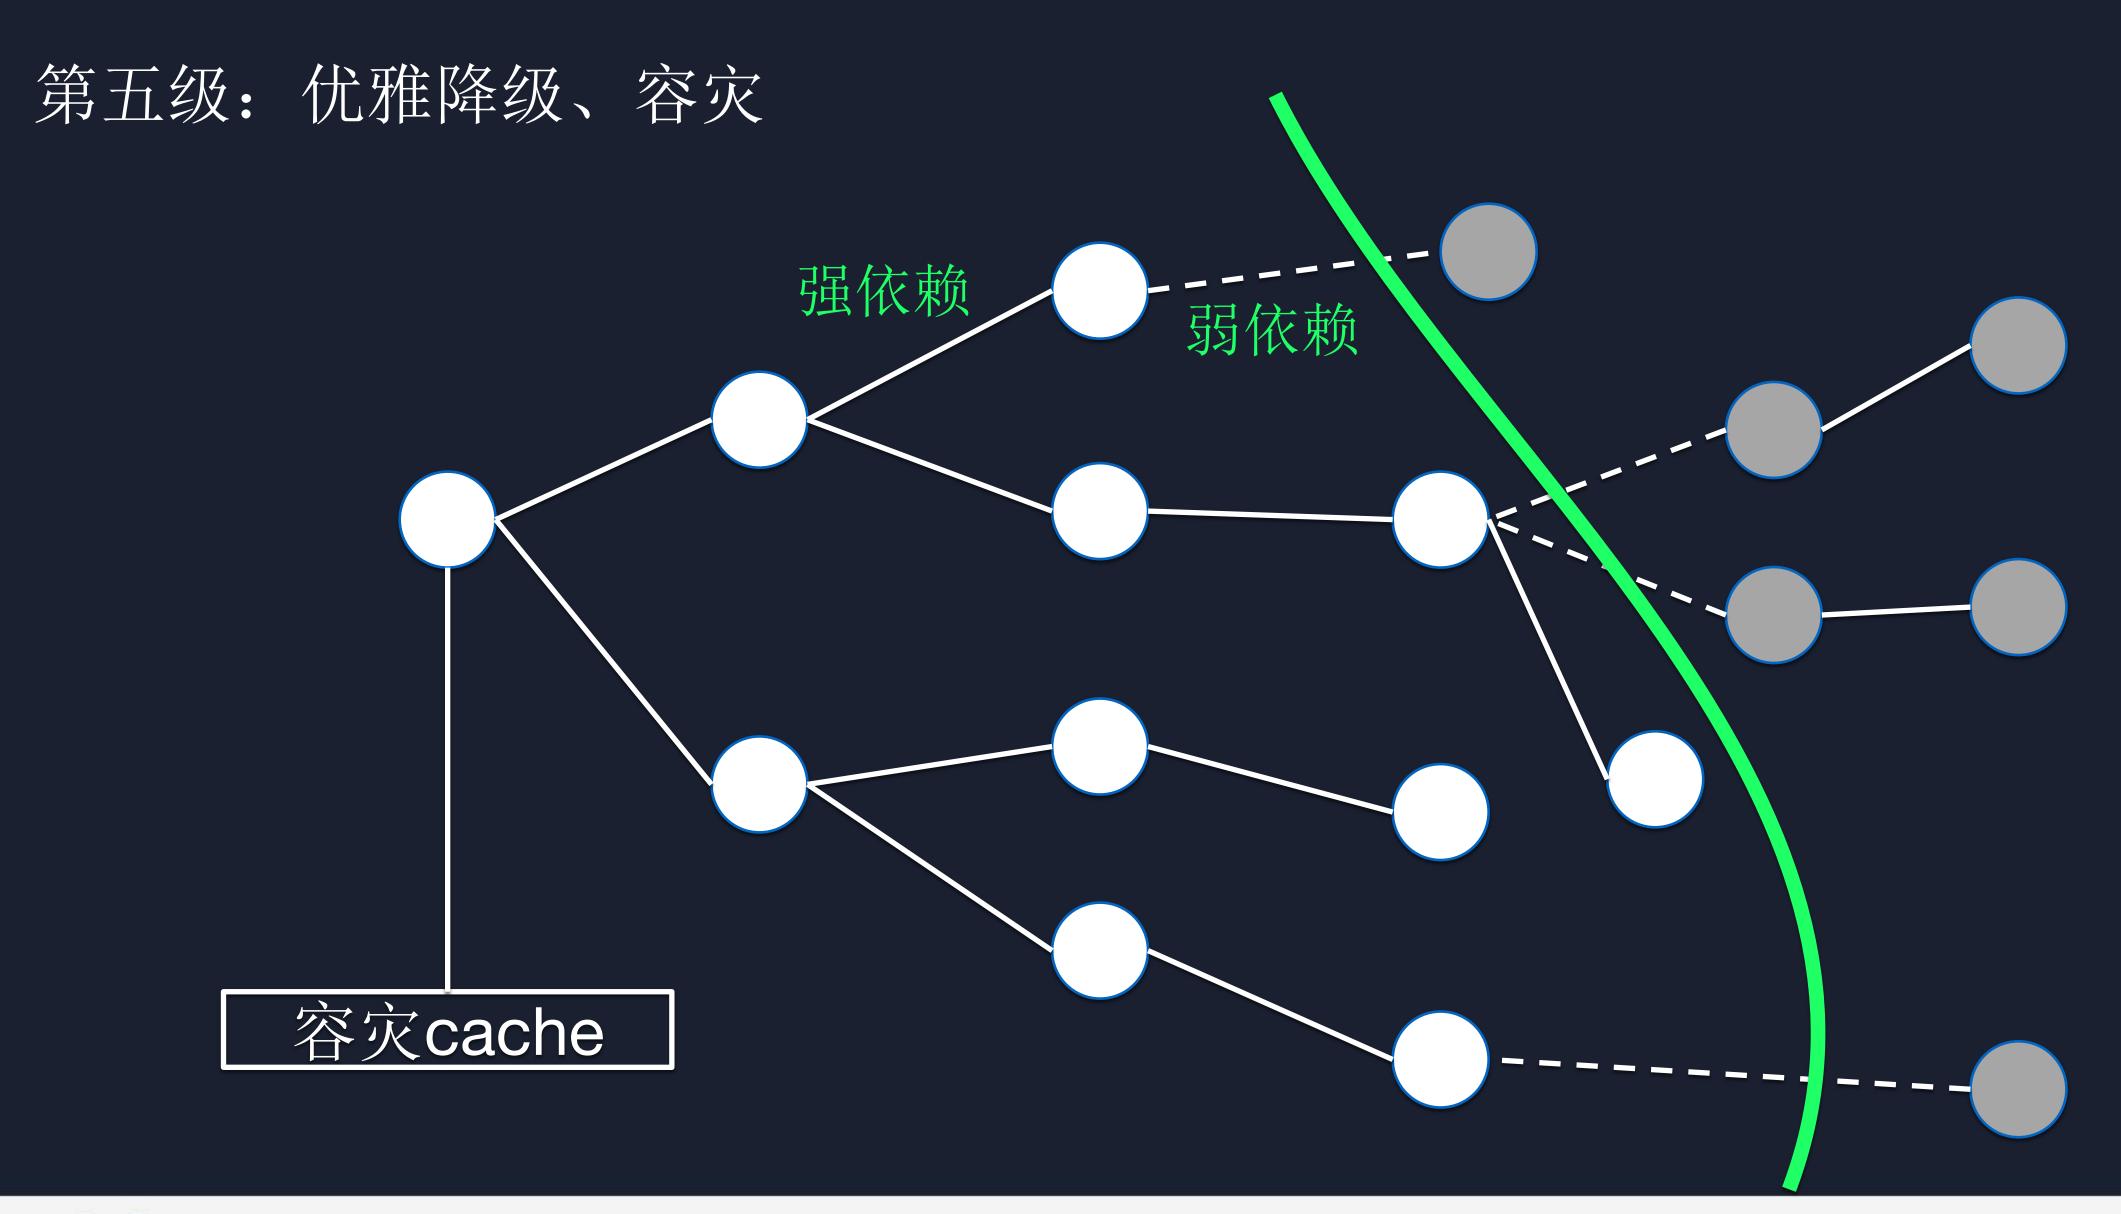


server层面:优先级限流



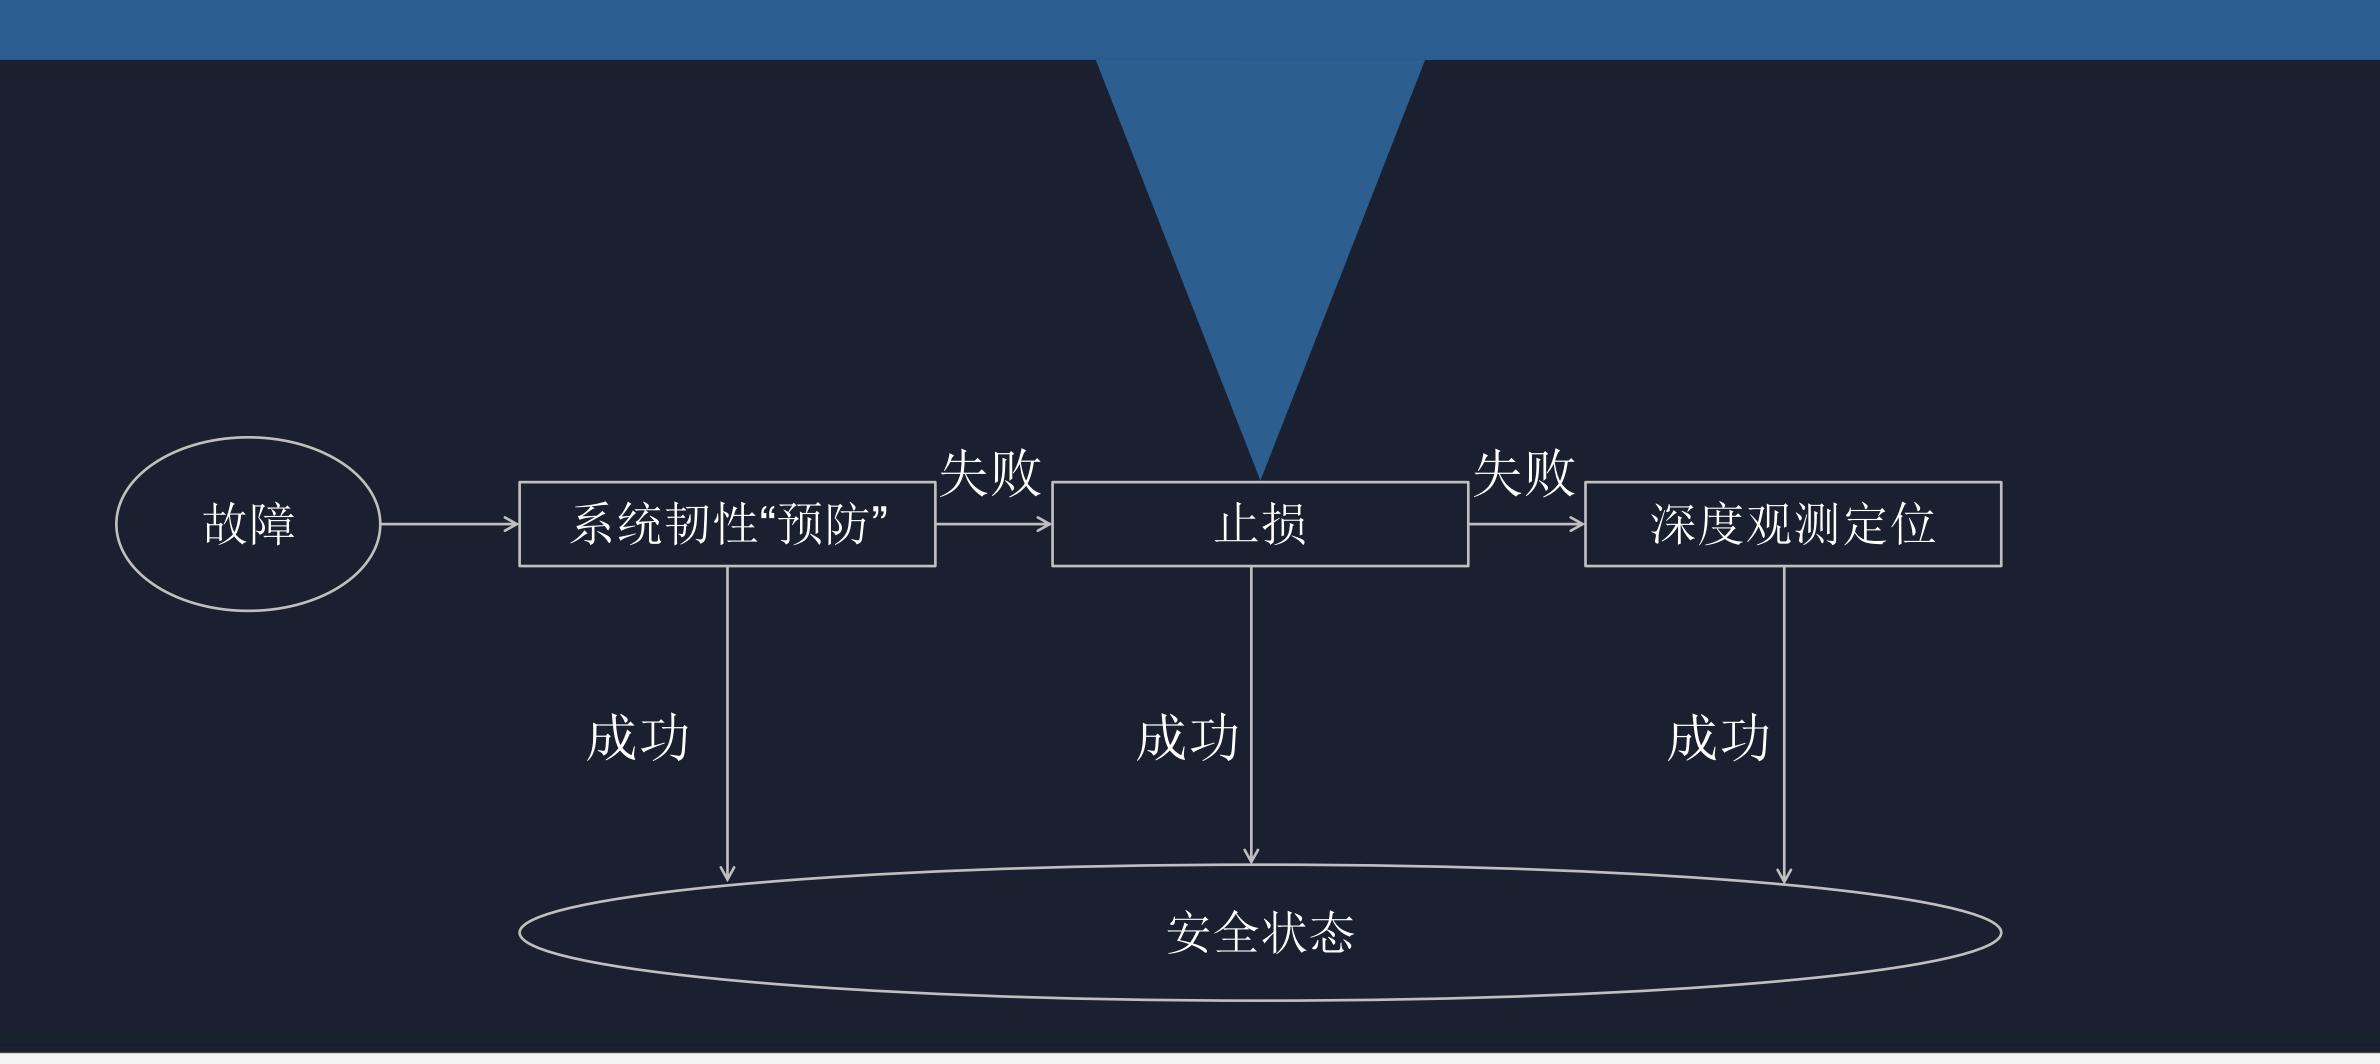


全面预防:流量调度框架| 兜底





精细止损一一流量切换、降级







精细止损

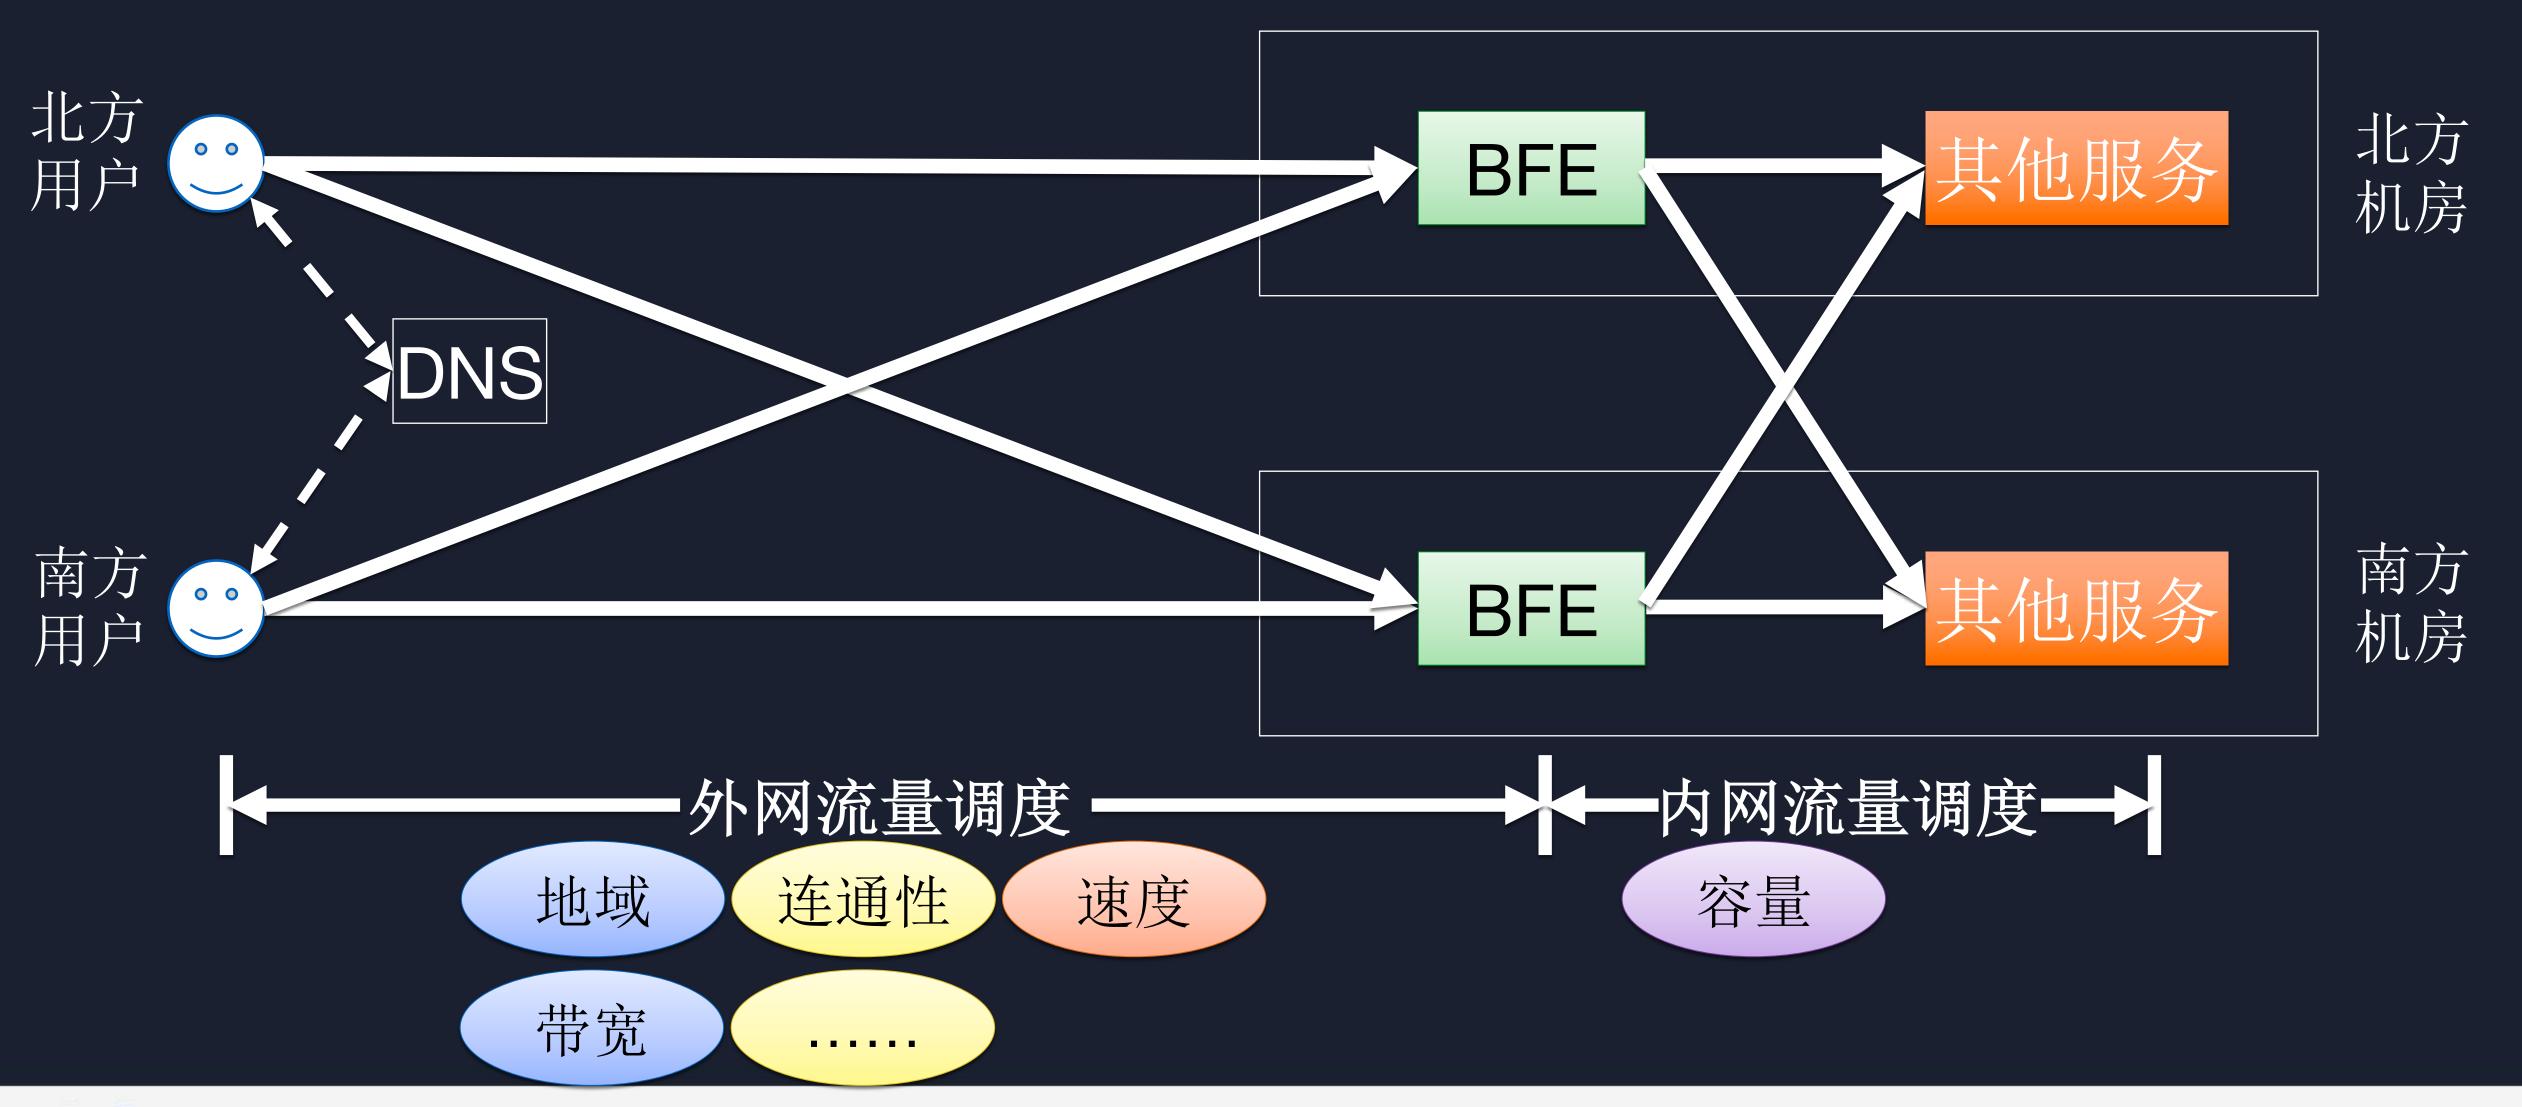
目标: 损失将要不可避免的发生、或者损失已产生,使损失最小。







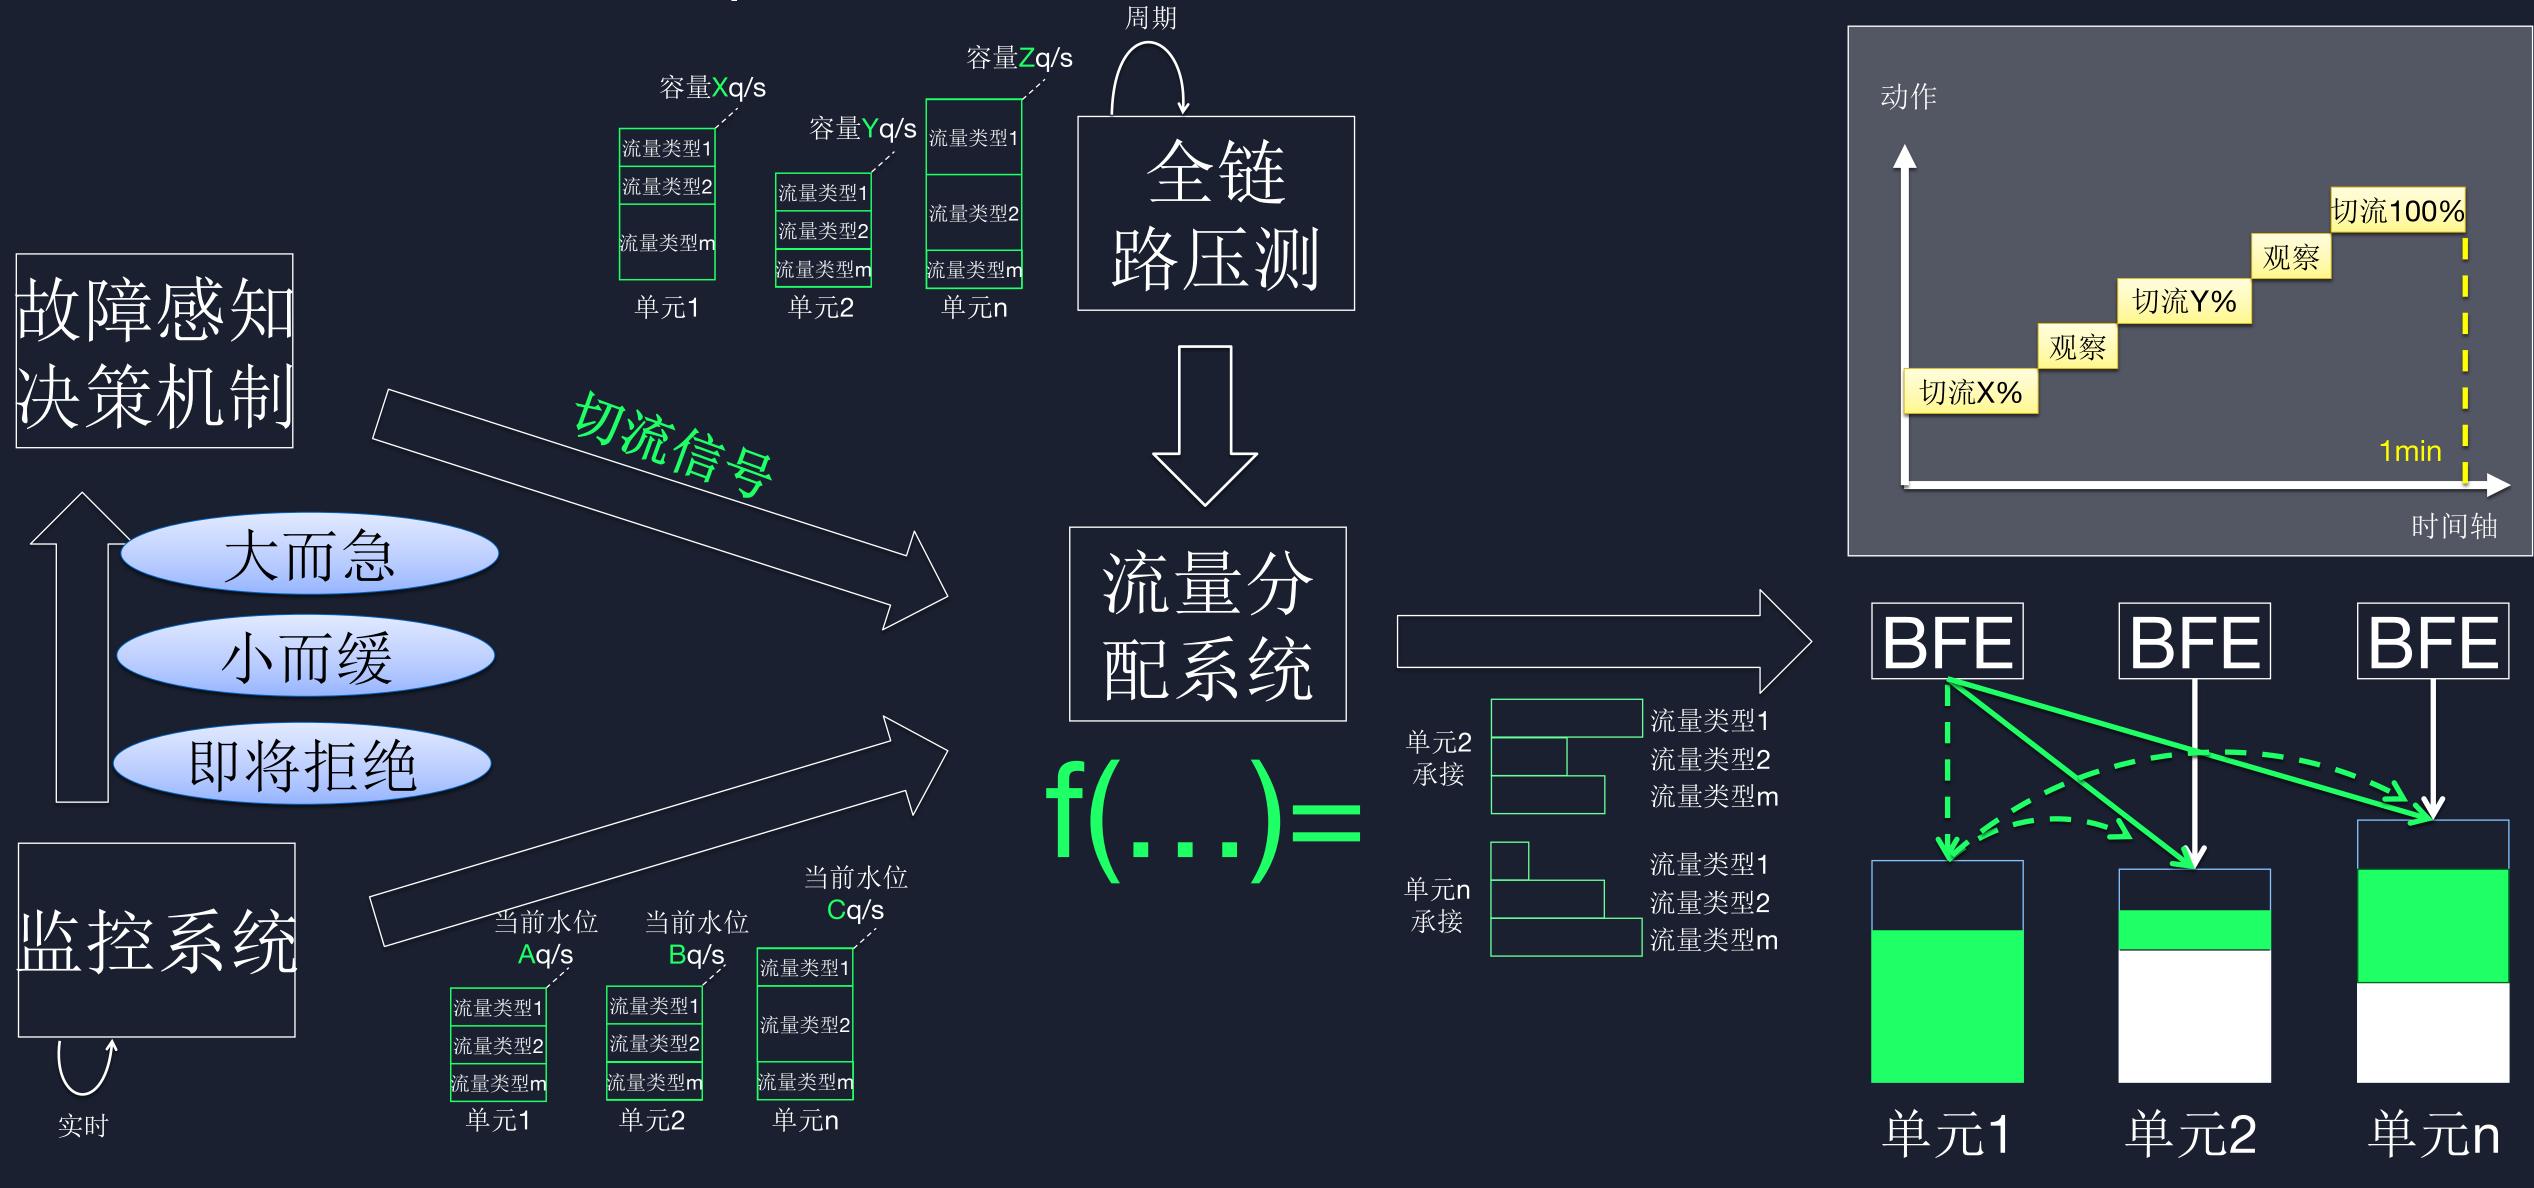
精细止损:流量切换全局视图







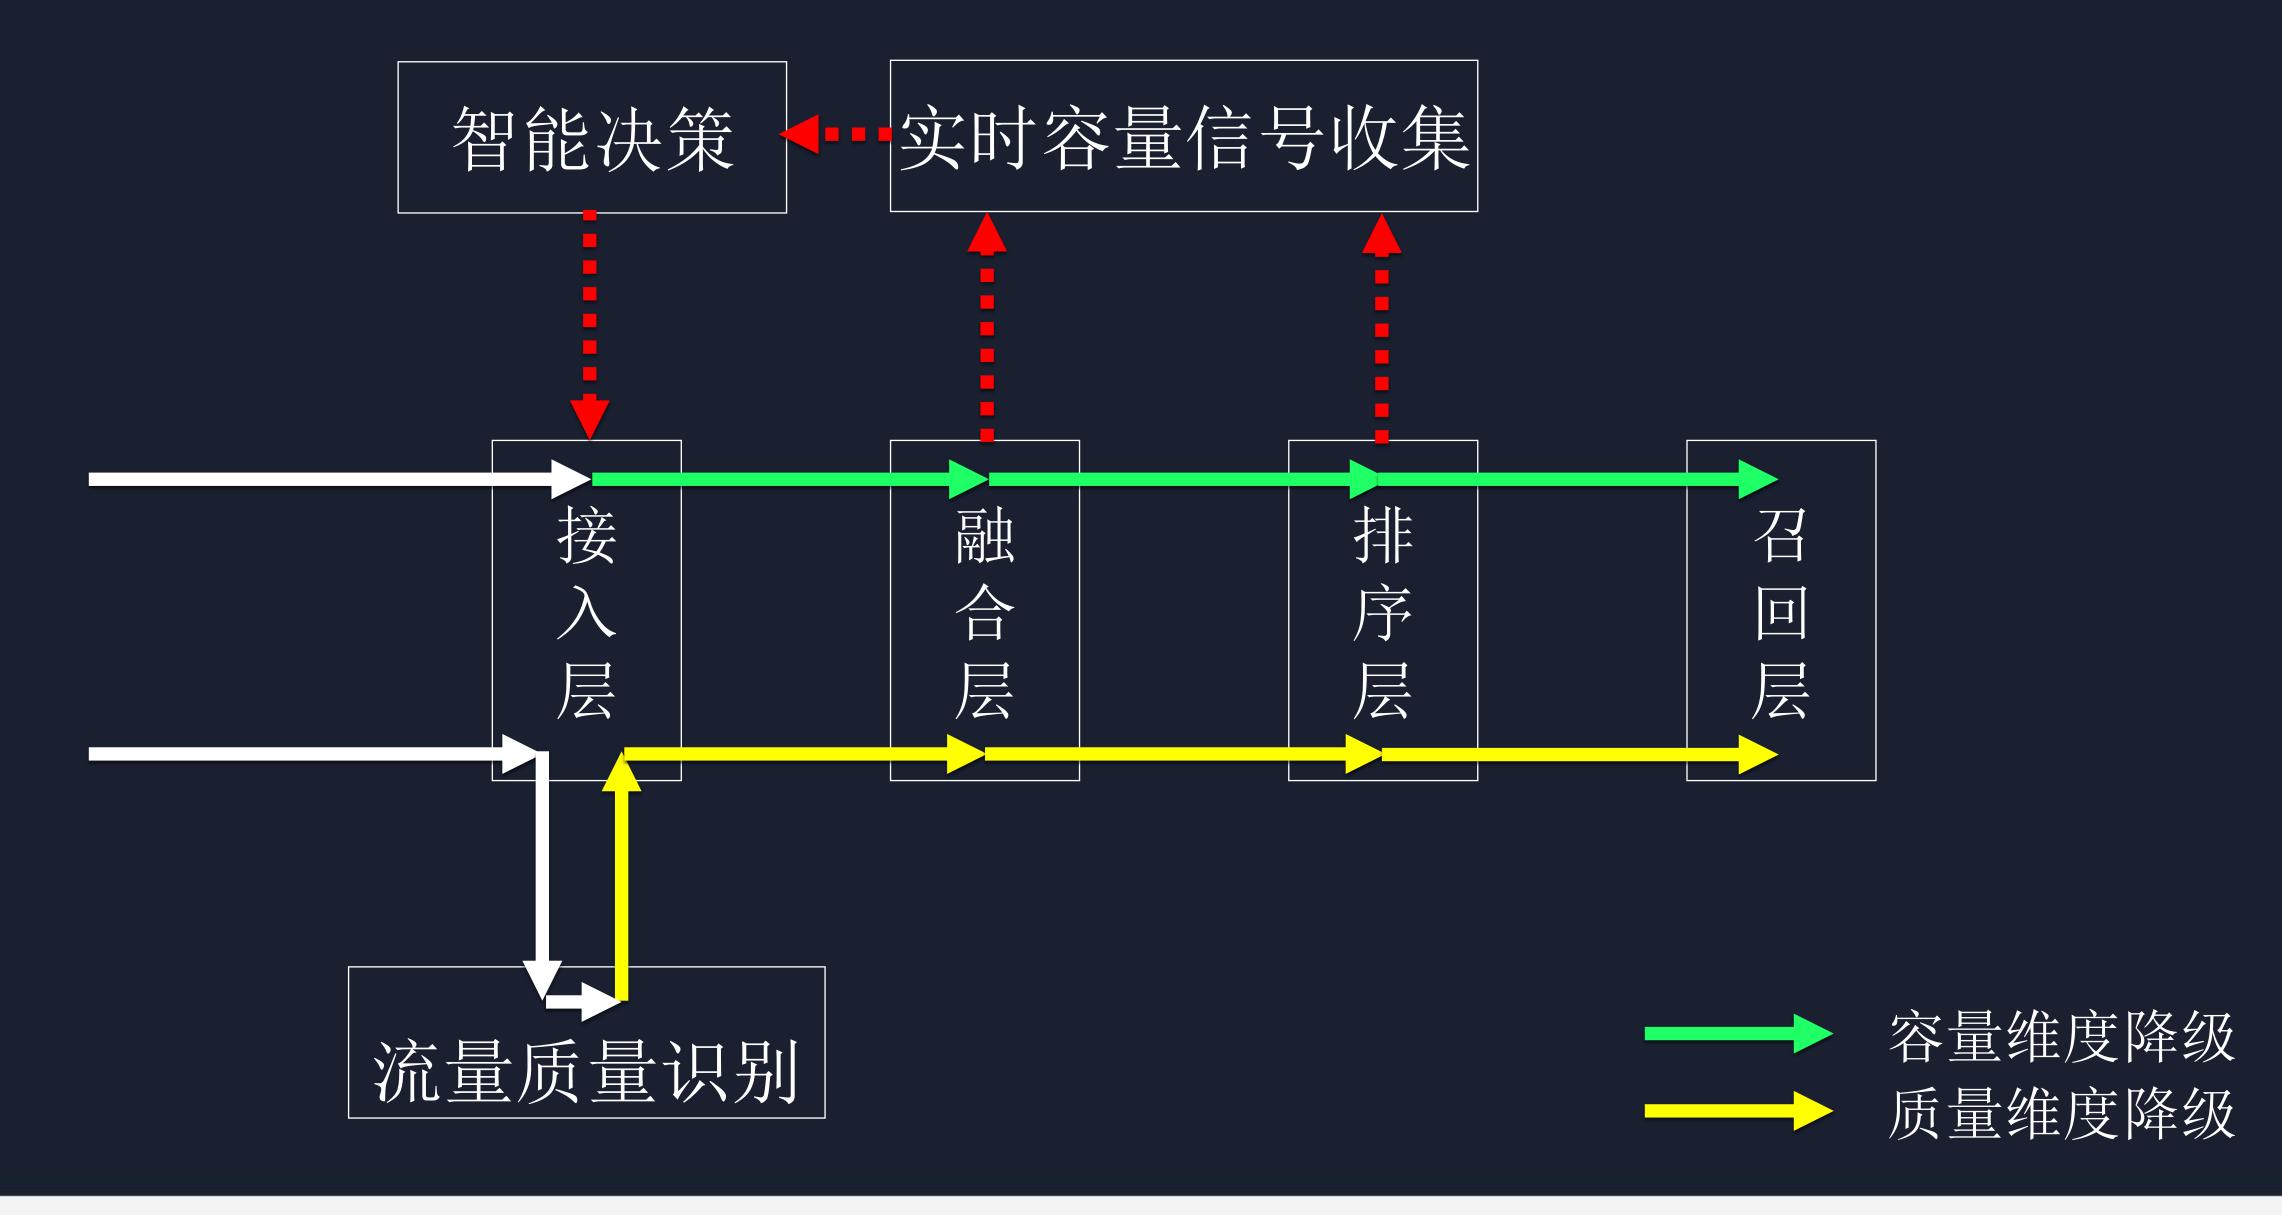
精细止损:流量切换 内网流量调度







精细止损:降级全自动降级

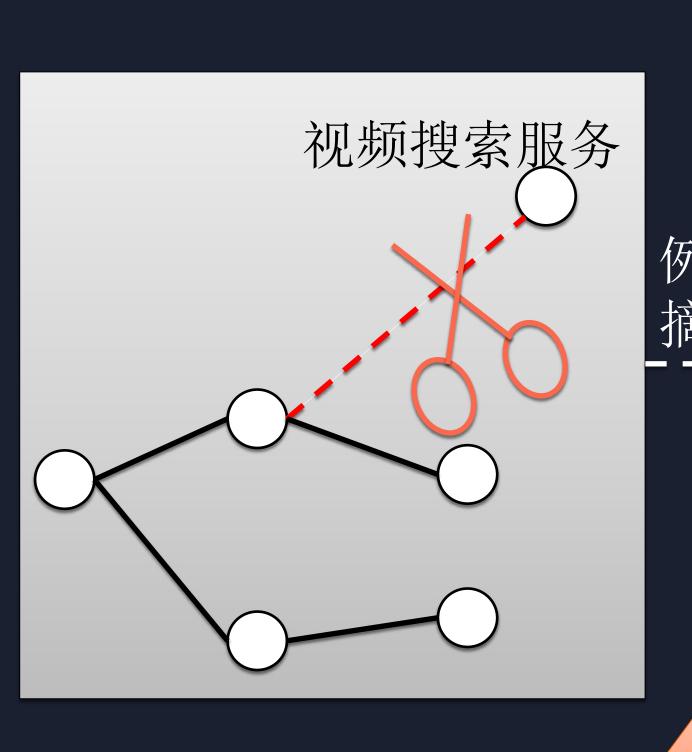


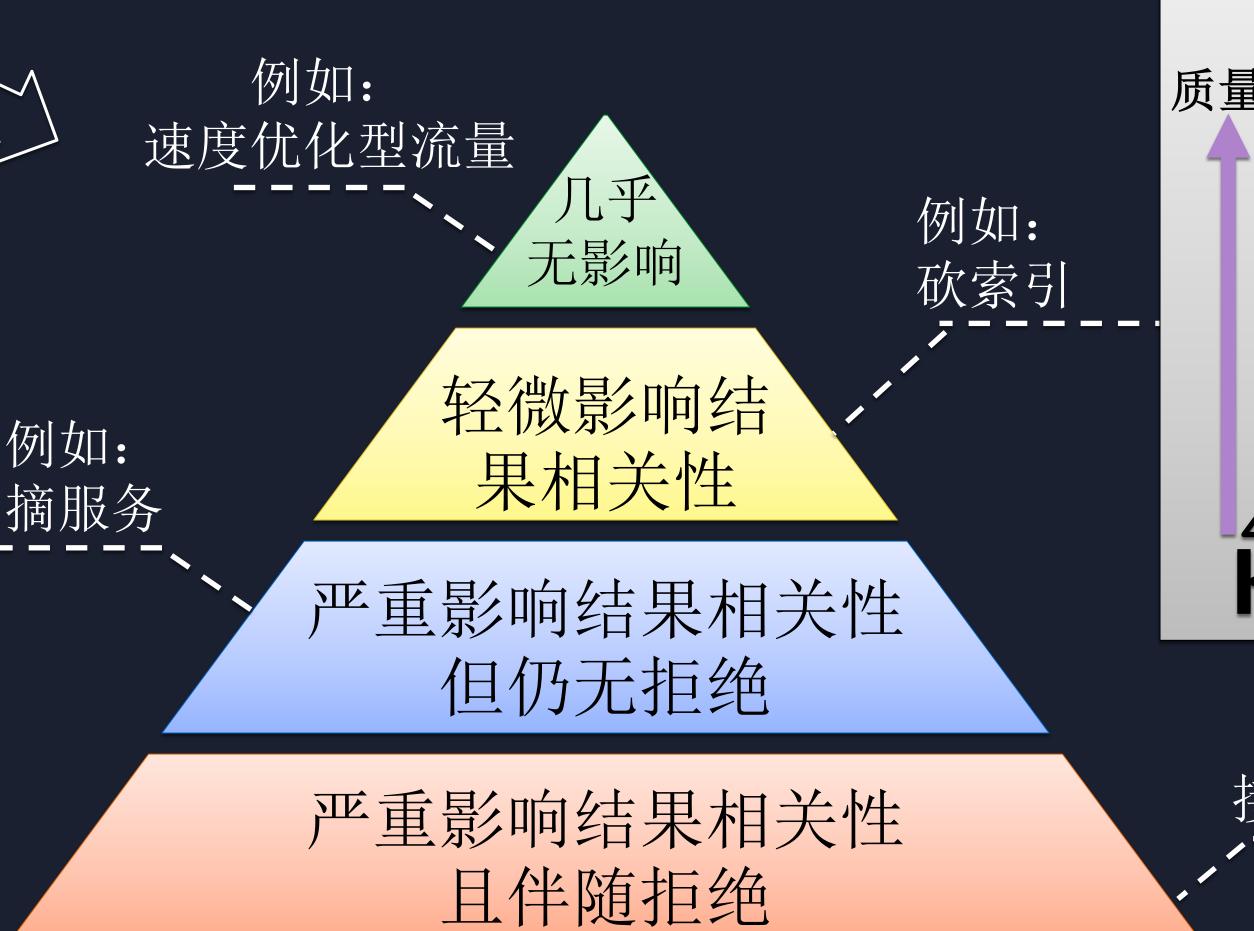


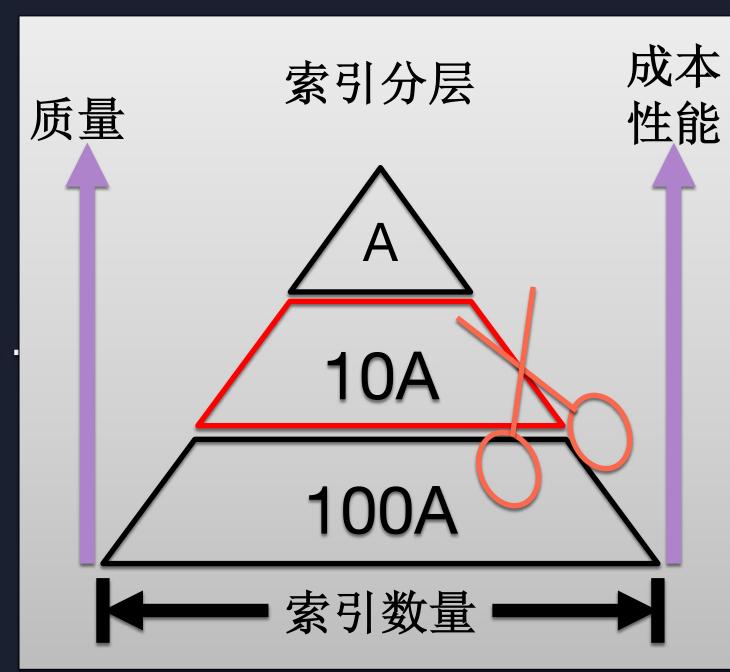


精细止损:降级半自动降级手段和烈度

机器/人工决策



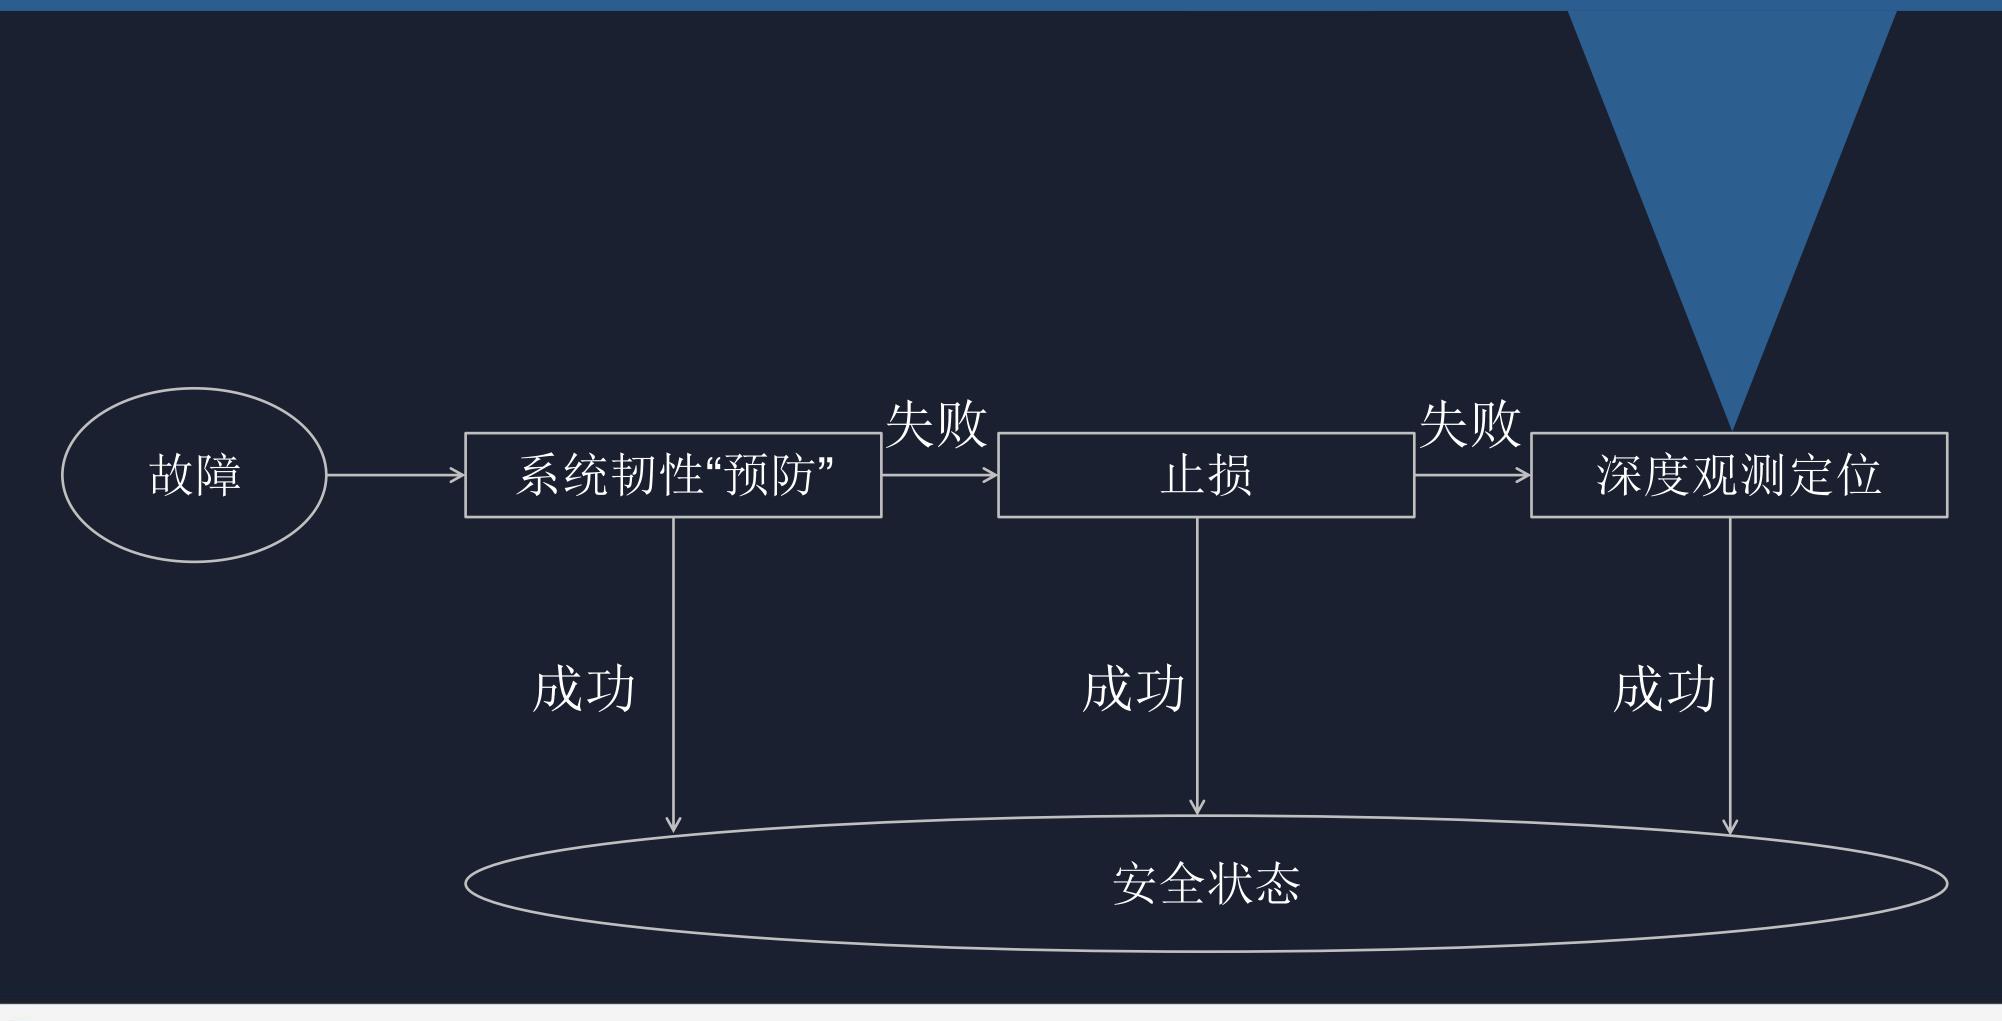




例如:接入层限流



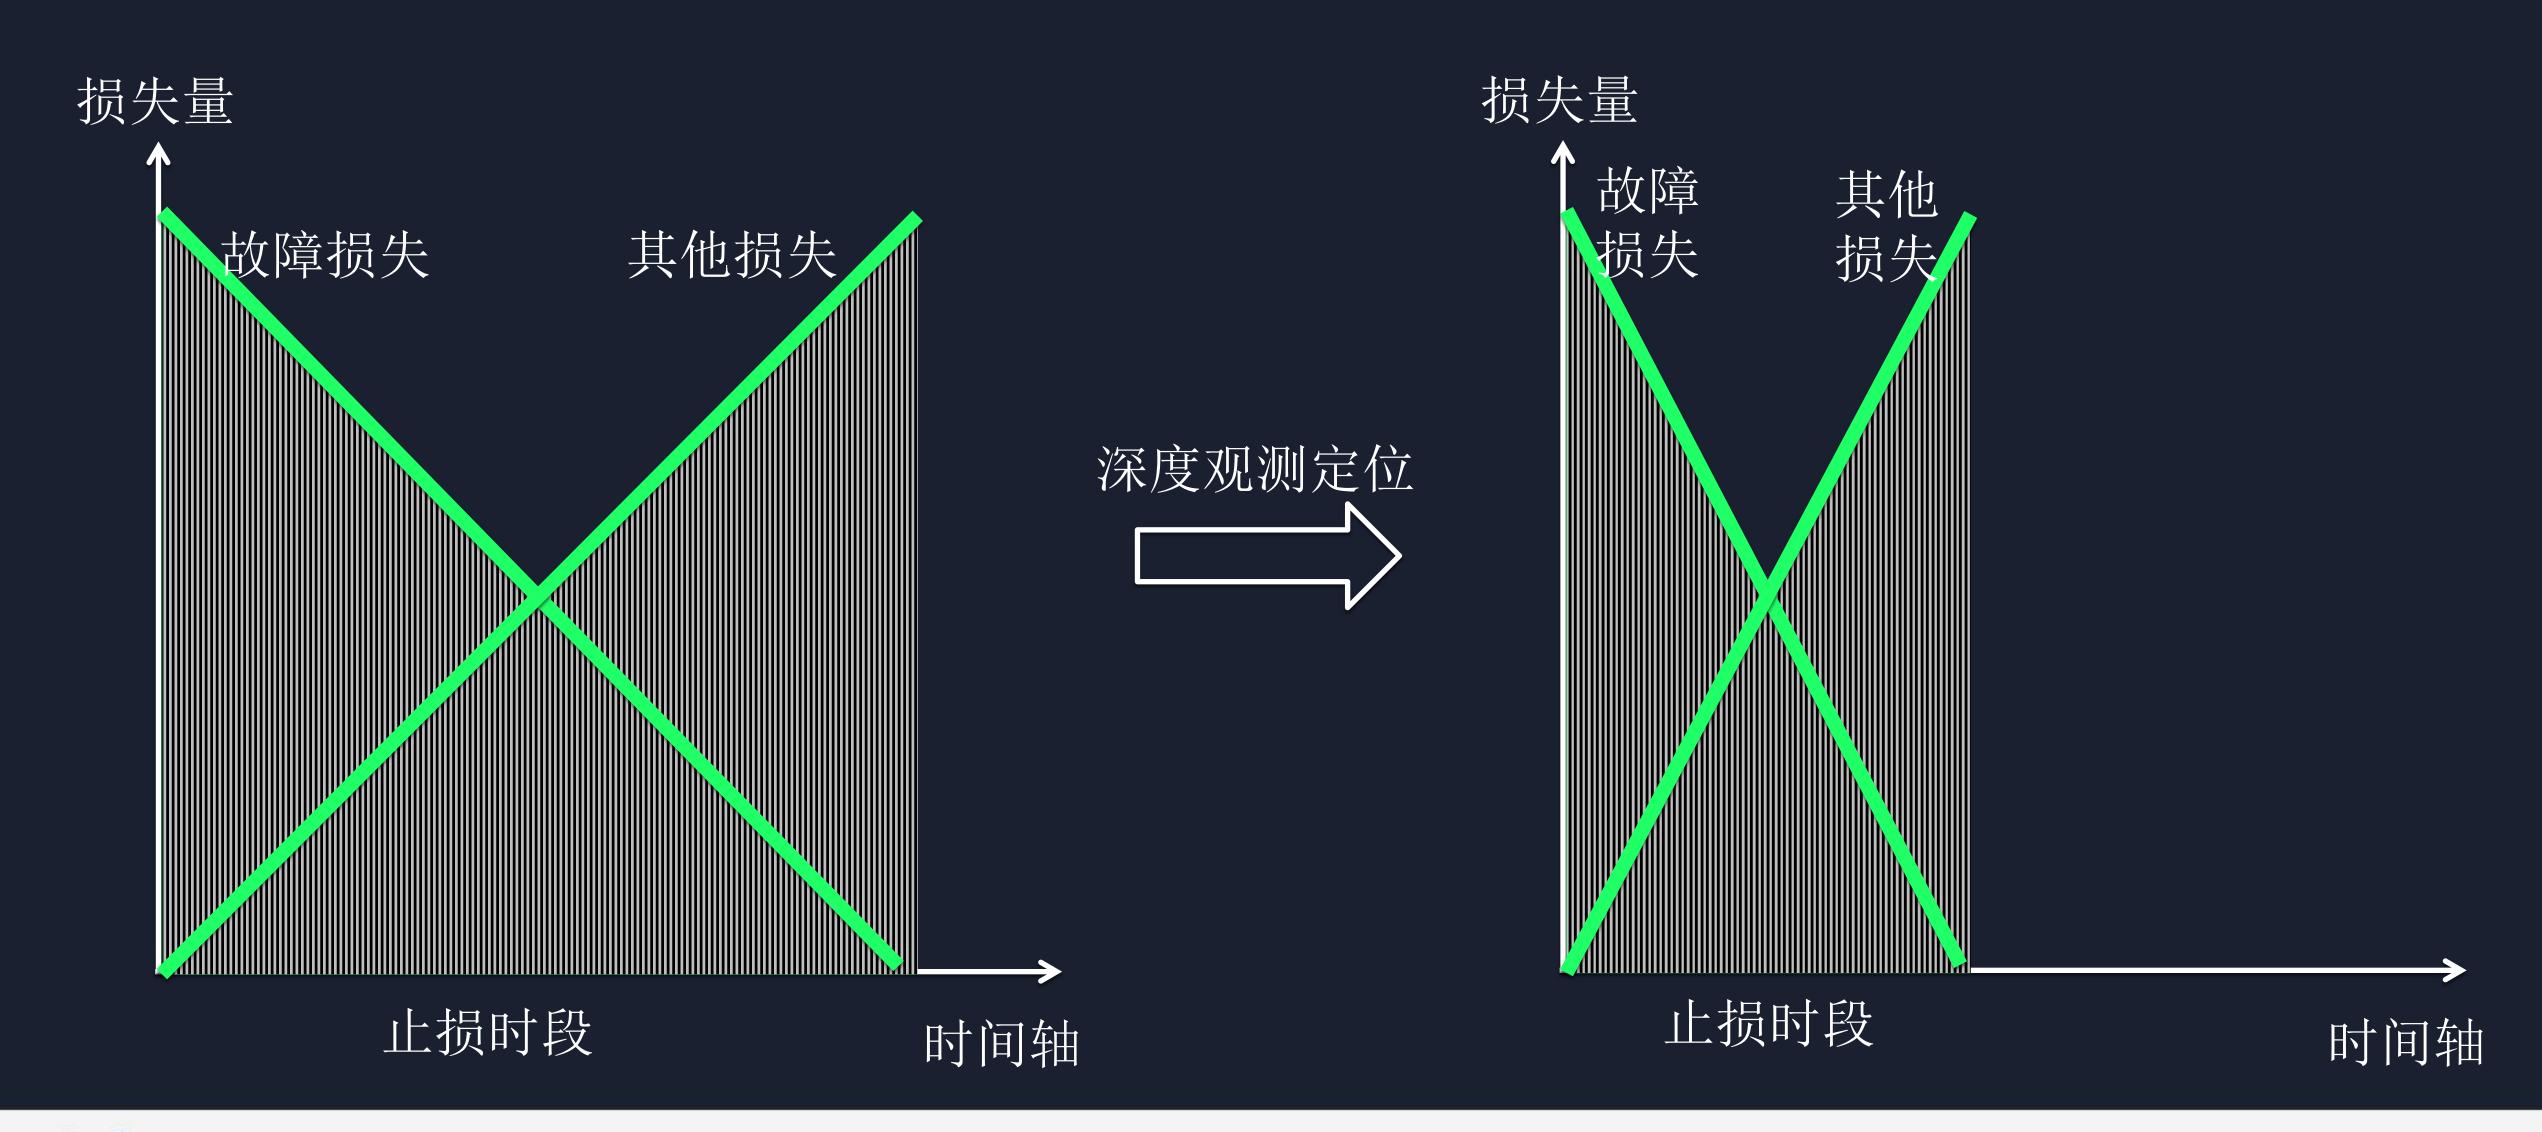
深度观测——tracing、logging、自动分析







深度观测追求







深度观测场景

故障未发生: 发现系统优化点

故障发生未止损: 有效止损

故障发生已止损: 彻底消除缺陷

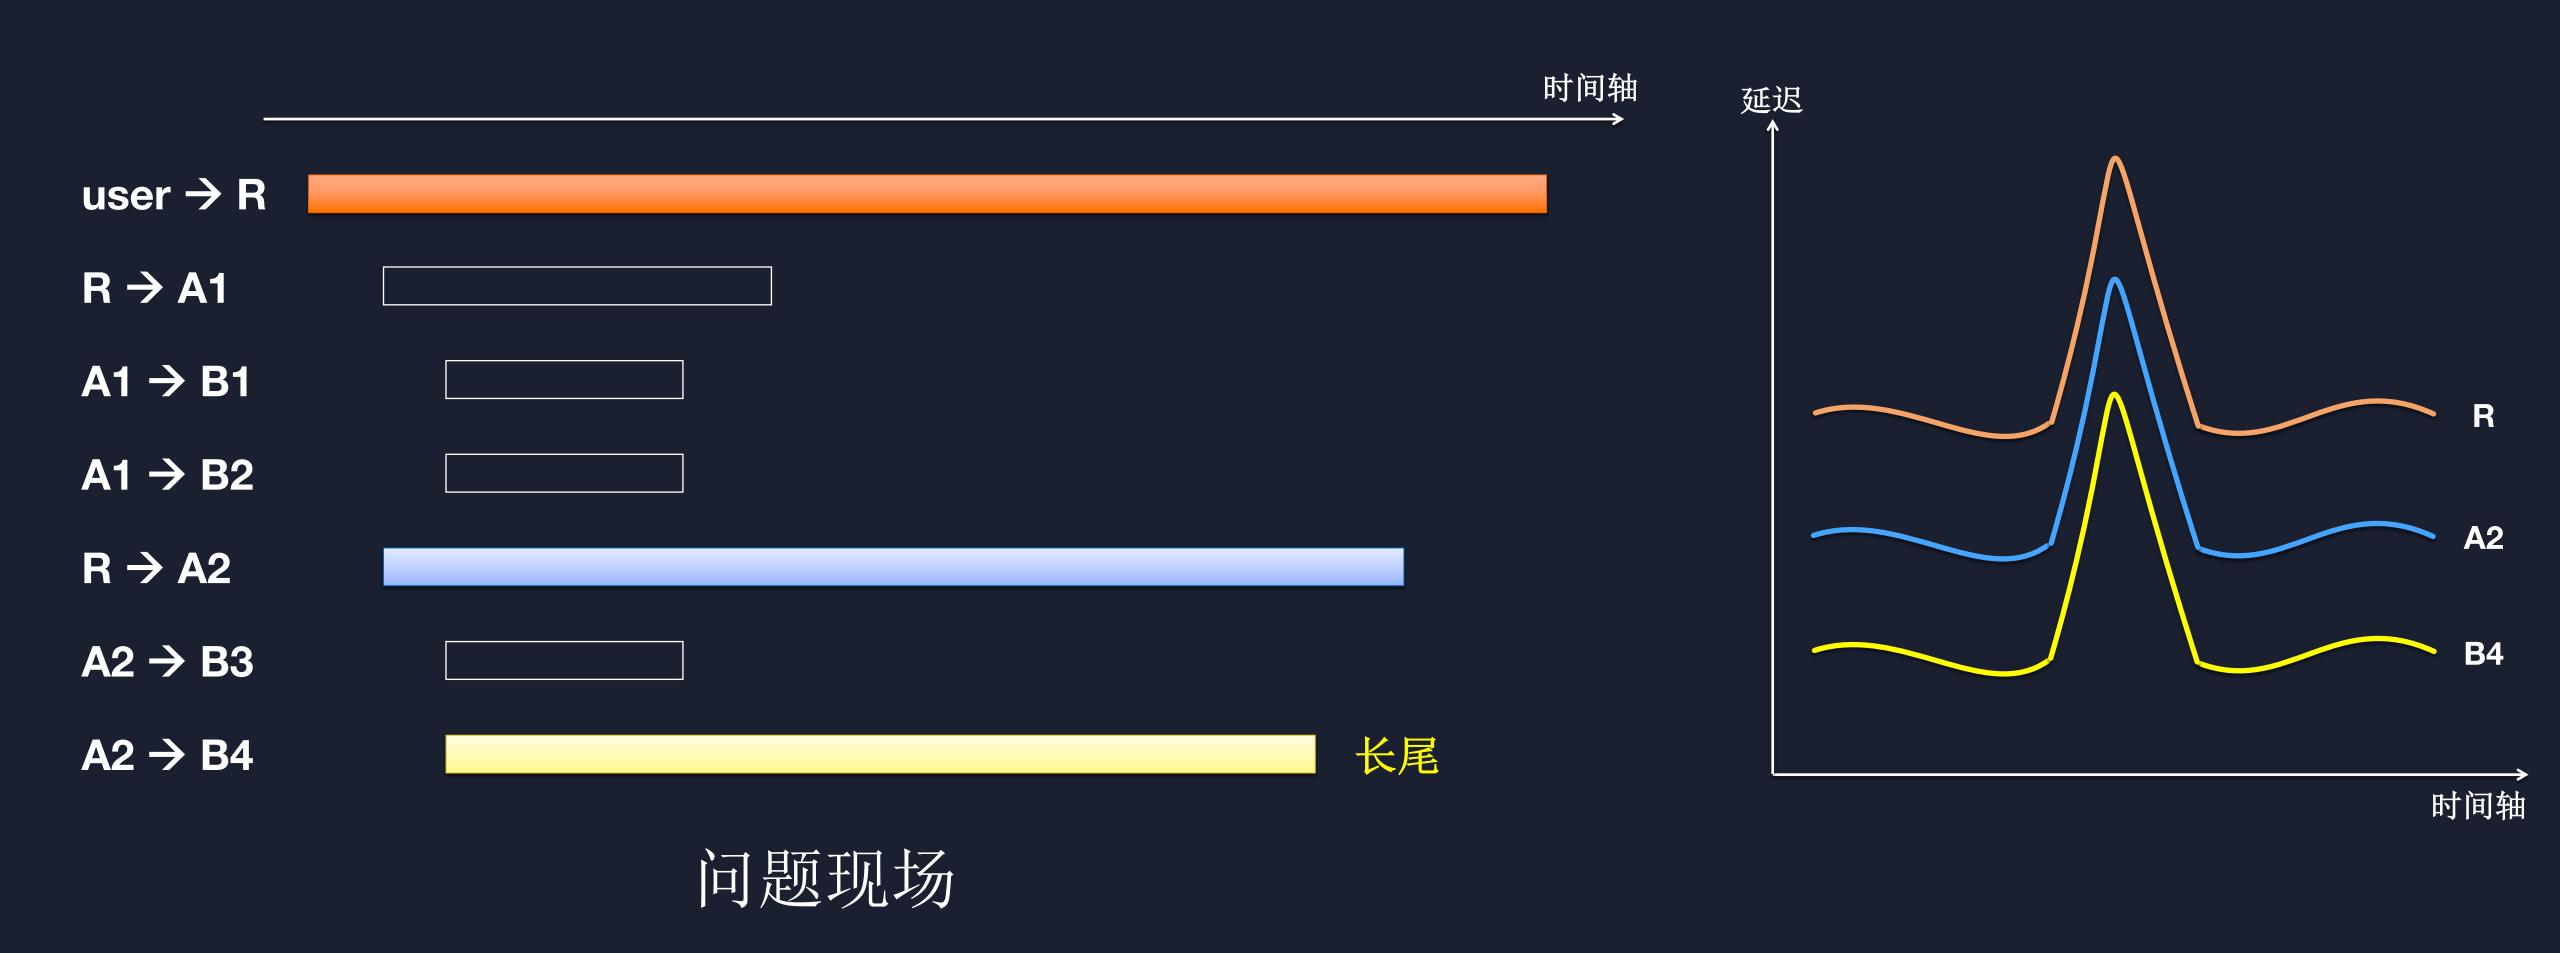






深度观测其他问题形态

速度问题







任意历史query的

节点信息

时序信息

日志信息





深度观测可观测性发展历史

理论: dapper模型 抽样模式 调度链和annotation

引进来(2014)

- 一定程度白盒化
- 部分query得以分析
- 资源开销大
- 历史query无法全部分析

自研 全量时序 全量日志

创新 (2016)

- 全量,数据建设彻底
- 任一query皆可分析
- 分析仍需人工参与

自研自动化故障分析

再创新(2017)

- 全自动分析
- lowcode扩展
- 革新了工作模式,效率极大提升

- pros
- cons





深度观测全量调用链全量日志系统——kepler

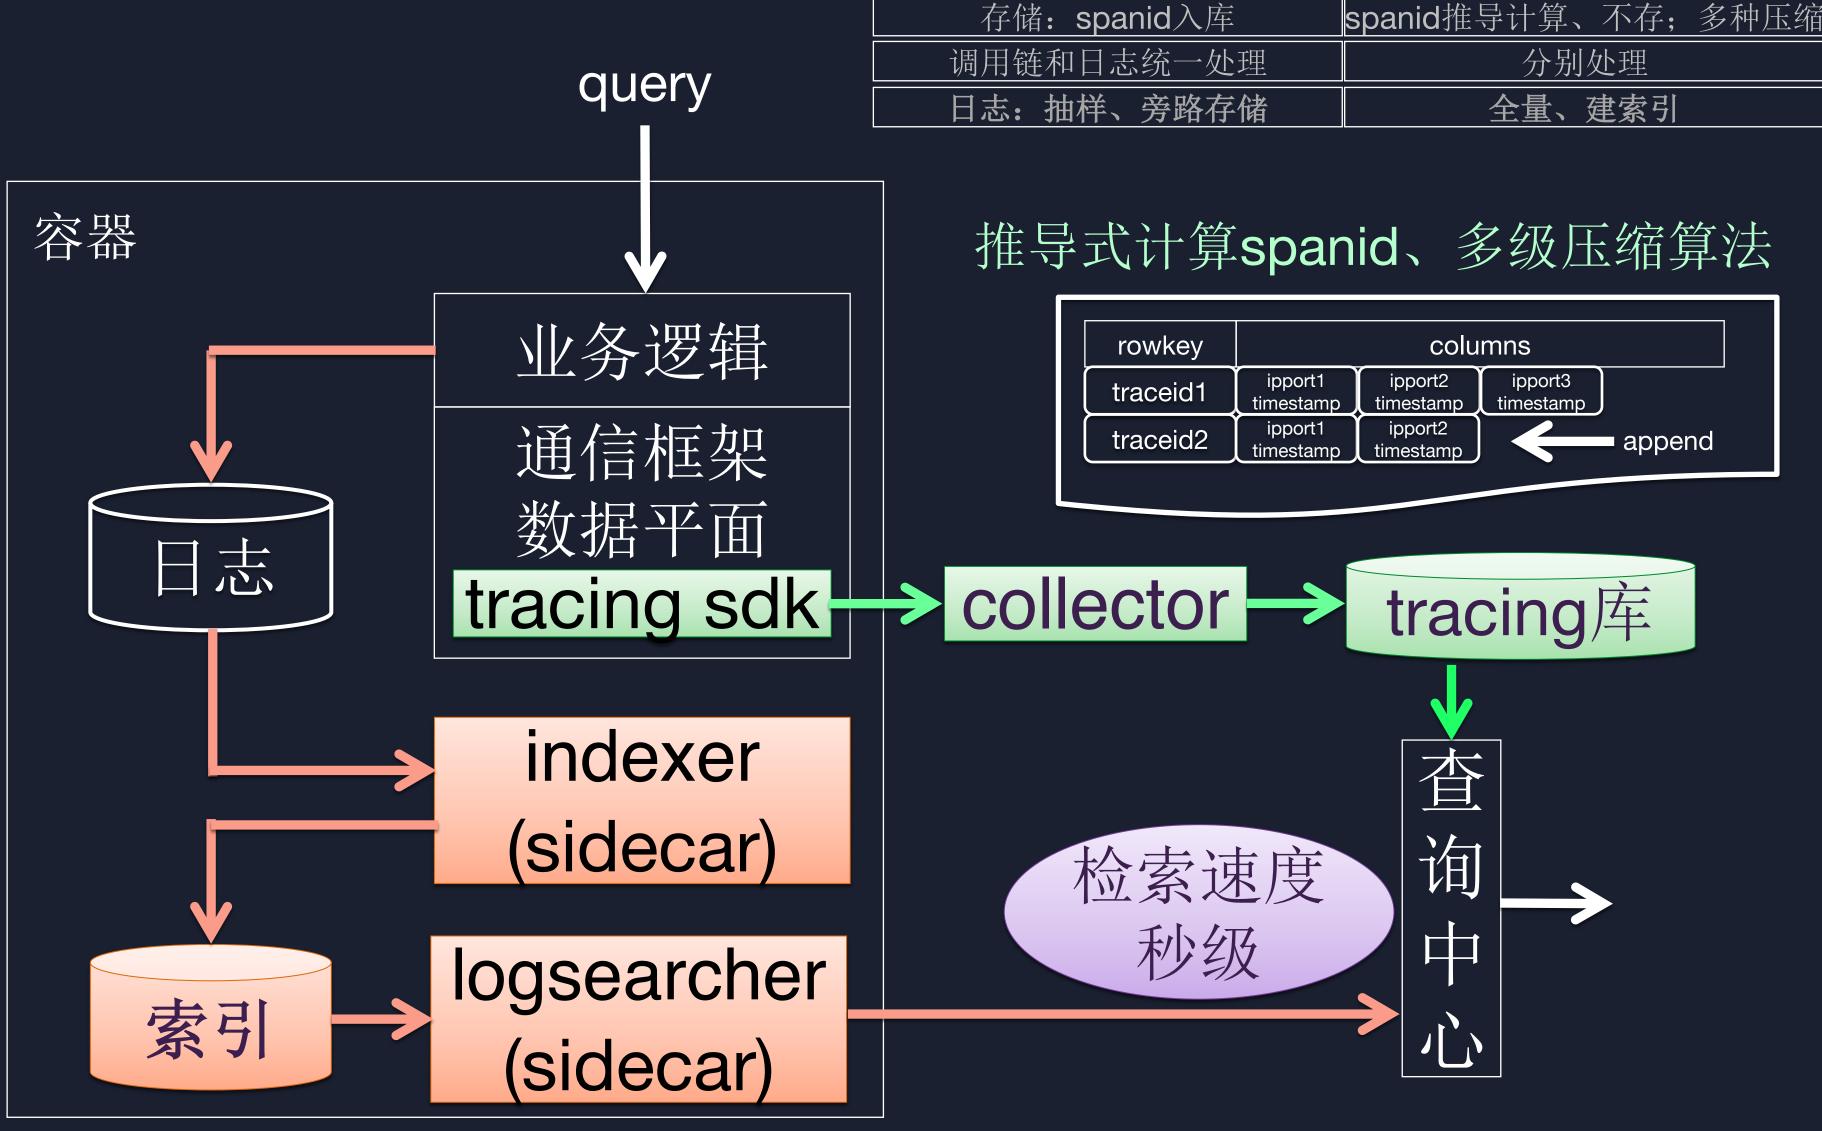


索引日志量 X PB

索引: 日志

1: X0





类dapper系统

调用链概念: traceid, spanid

基于抽样





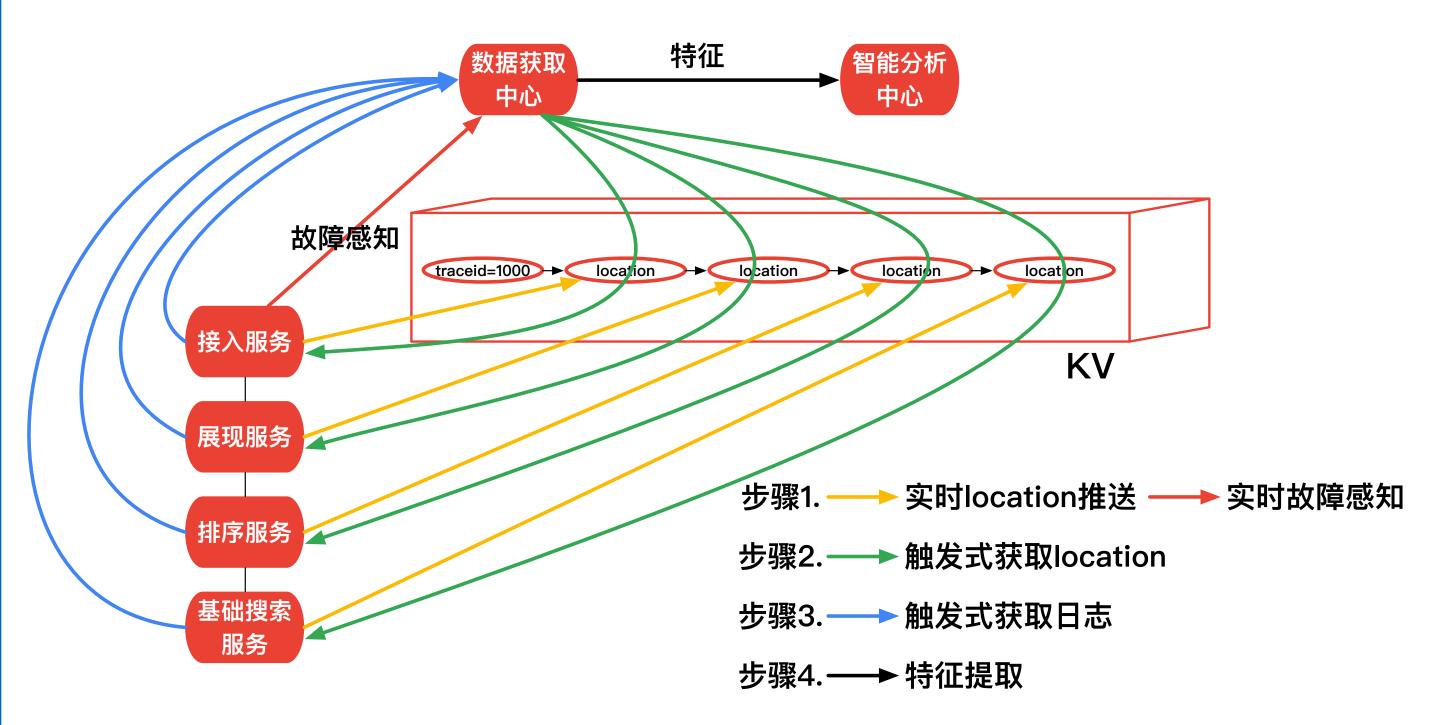
我们

相同

全量

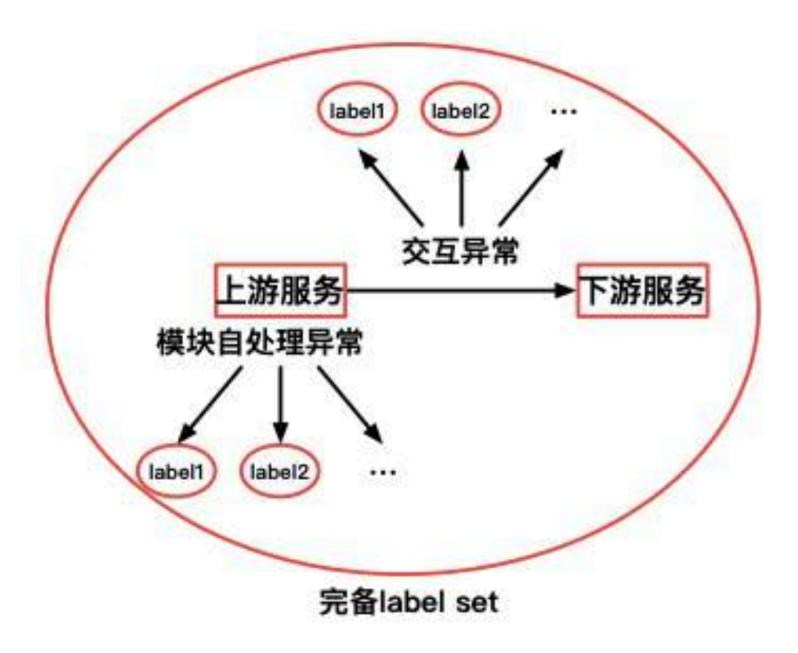
深度观测拒绝自动分析系统——巨浪

通路



思考题:步骤1中的两条流是否需要有先后顺序?

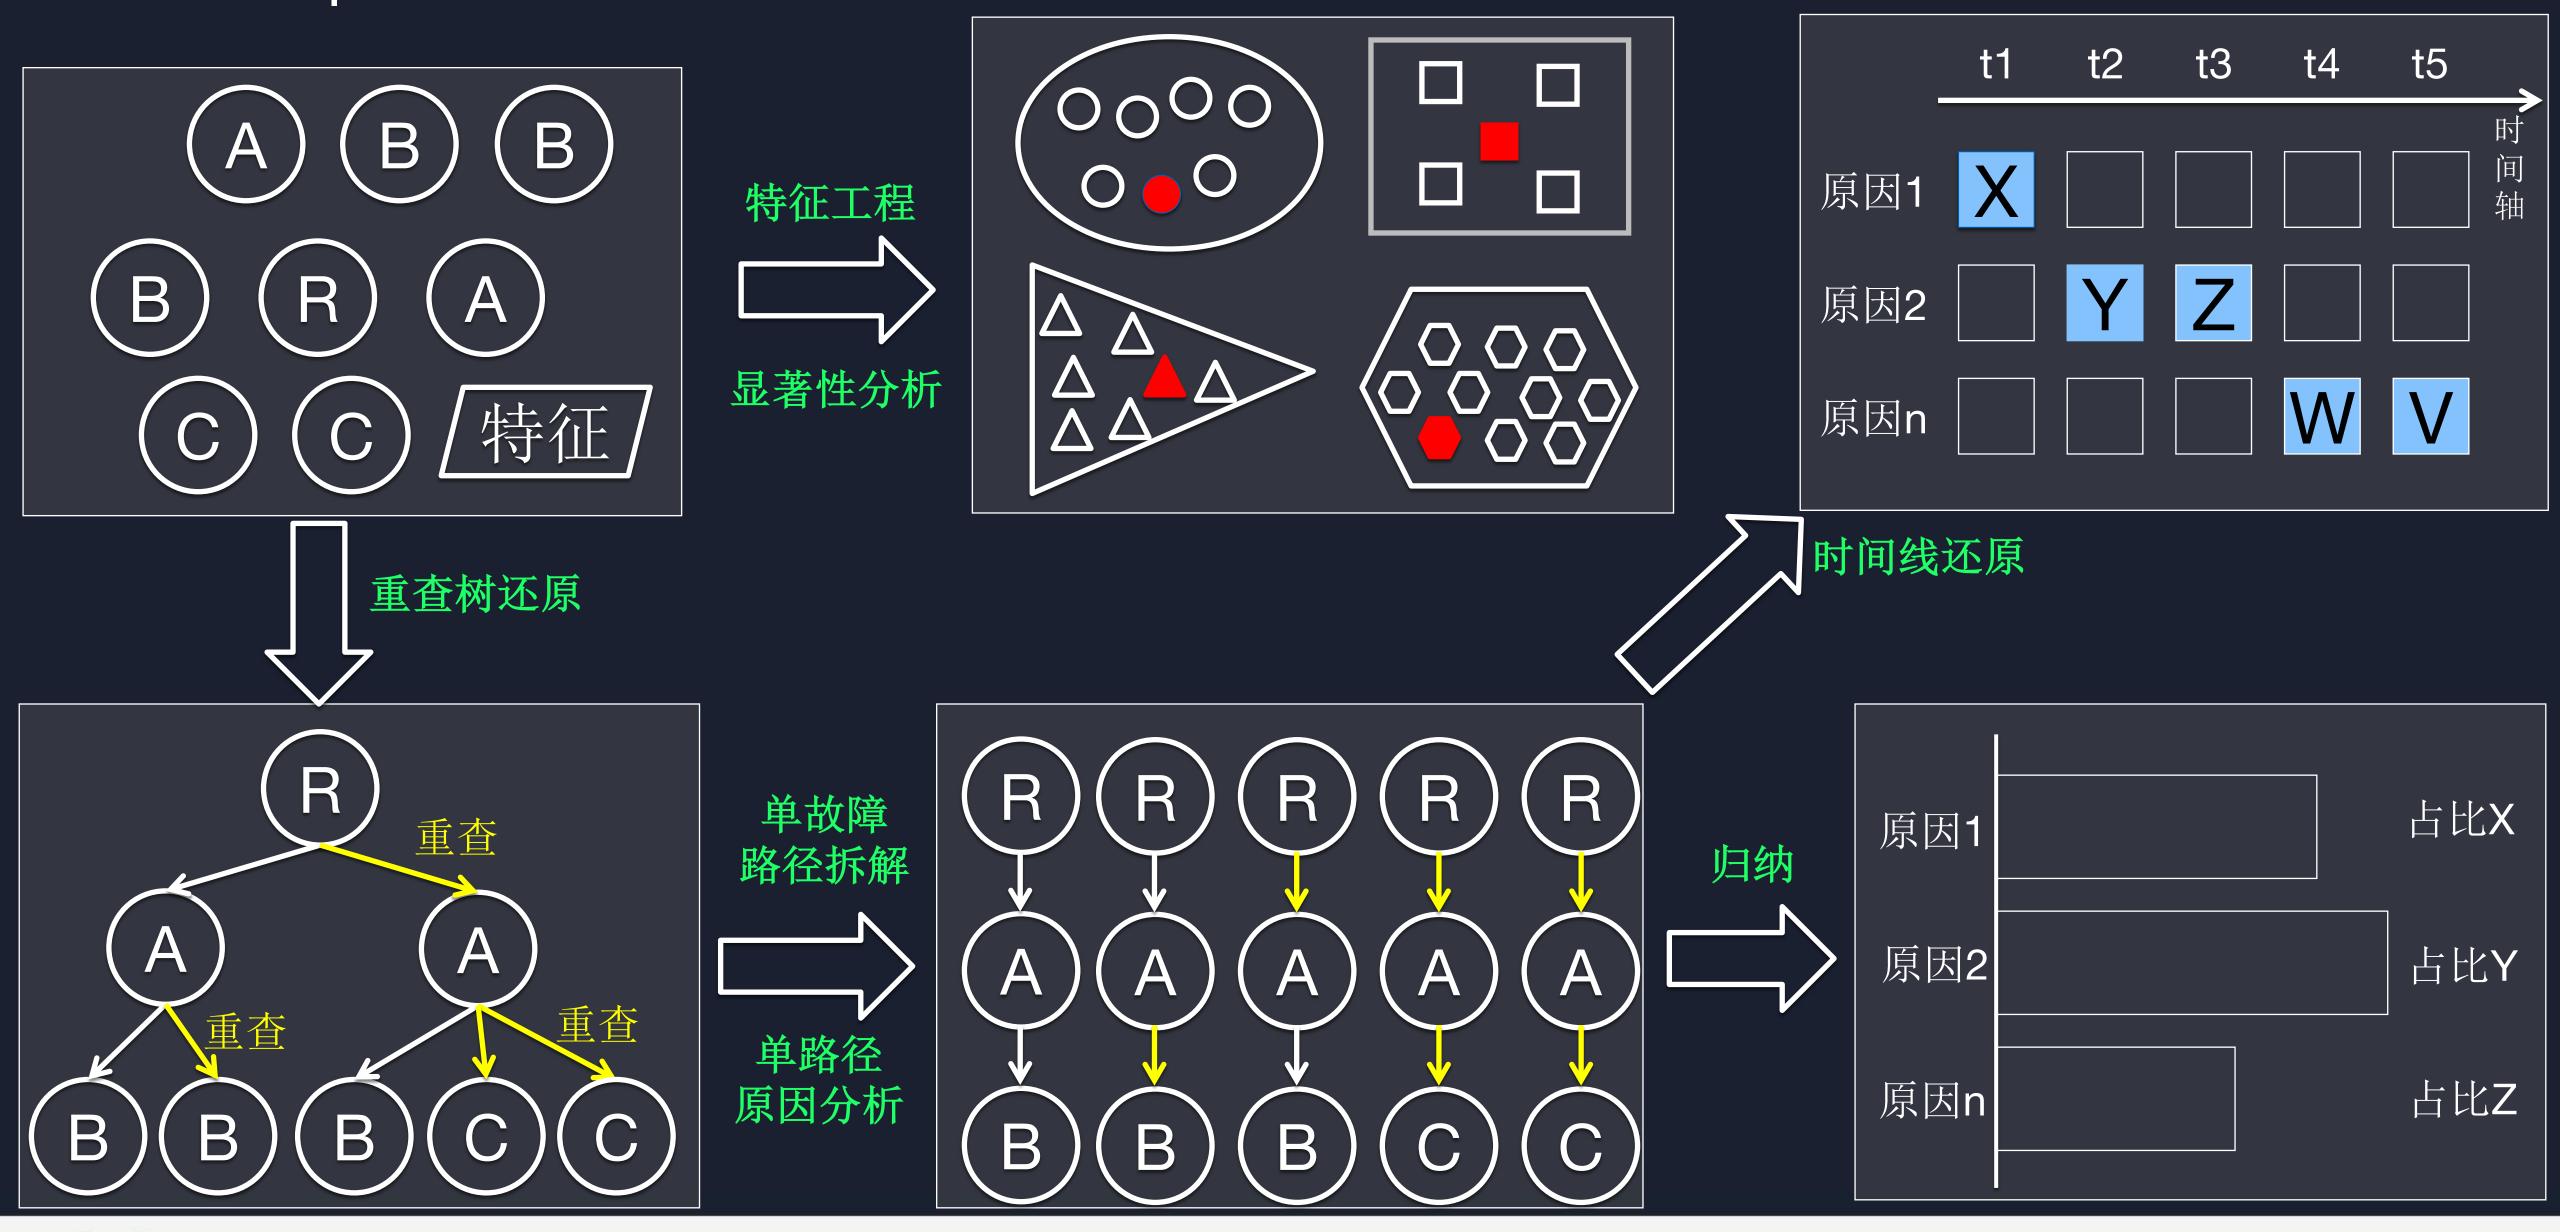
完备label set







深度观测拒绝自动分析系统——巨浪





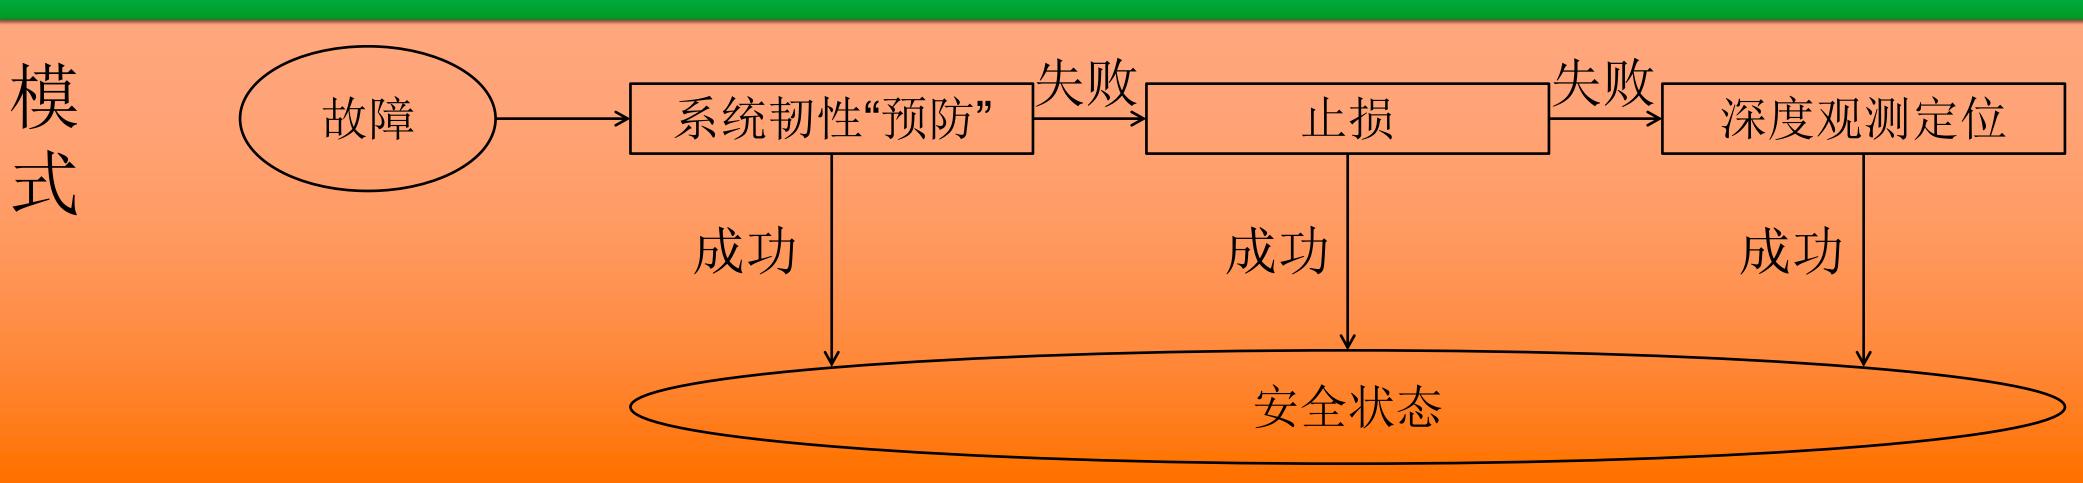


台名





目标:尽最大可能服务好query,减少损失



全面预防

目标: 提升系统韧性

组件之一:流量调度框架

多级治理手段:

- 1. 以小代价选择可用的server实例
- 2. 分片模式下动态丢层防延迟长尾
- 3. 副本模式下多种负载均衡防延迟长尾
- 4. 对server的多种保护使整体损失最小
- 5. 弱依赖容忍、强依赖容灾兜底

精细止损

目标: 提供无脑但又相对精确、迅速的

手段

相关机制:流量切换、降级

流量切换:精准感知、安全高效执行

降级: 多种手段释放系统容量

深度观测

目标: 根因快速定位

原则:

1. 正视数据需求,毫不妥协地进行数据建设,建设全量tracing和logging

2. 故障分析全自动化,形成"非智力型"过程,解放人力,提升效率









关注 InfoQ Pro 服务号

你将获得:

- ☑ InfoQ 技术大会讲师 PPT 分享
- ☑ 最新全球 IT 要闻
- ◎ 一线专家实操技术案例
- ✓ InfoQ 精选课程及活动
- ② 定期粉丝专属福利活动





